Lab 7 · 110 นาที · สัปดาห์ที่ 7

คำนวณเพิ่มจากผลลัพธ์ โดยไม่ต้องเขียน SQL

Rolling Window · Time Comparison · Resample · Annotation Layers

ทุกอย่างวันนี้อยู่ในแท็บ **Advanced Analytics** ของหน้า Explore

วันนี้ทำอะไร

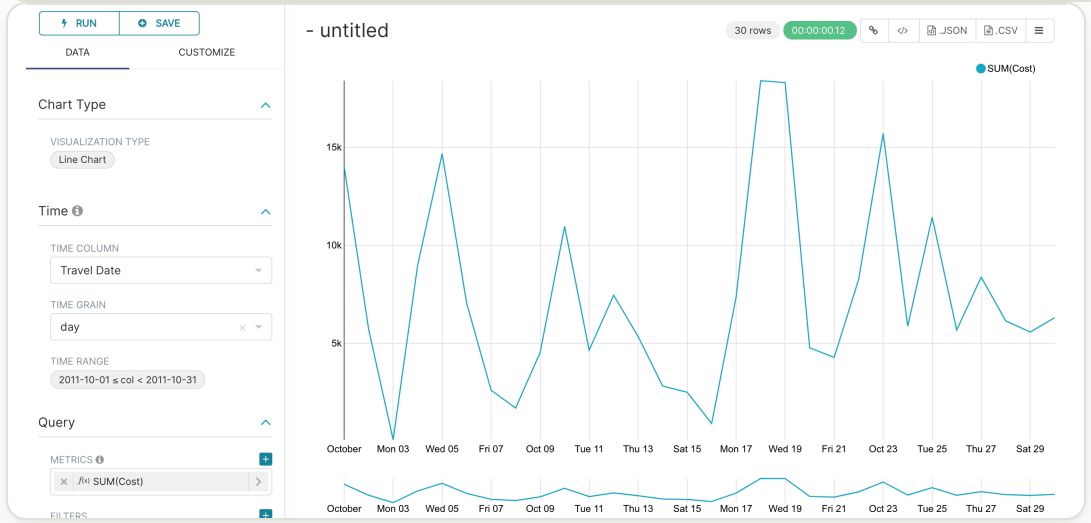
สี่ช่วง บวก Challenge

ตอน	ทำอะไร	เวลา
1	ค่าเฉลี่ยเคลื่อนที่ 7 วัน พร้อม **Min Periods**	30 น.
2	Annotation Layer ที่ **ตั้งชื่อแล้ว**	20 น.
3	Time Comparison + Resample	25 น.
	Challenge — ลอง Periods 30 แล้วดูว่าเหลือเส้นเท่าไร	5 น.
4	สำรวจข้อมูลขั้นที่ 3 — Box Plot และ outlier	30 น.

ตอนที่ 1 · ค่าที่ต้องกรอก

เฉลี่ยเคลื่อนที่ 7 วัน

```
ชนิดกราฟ : Line Chart   X-axis : Travel Date   Time Grain : Day
Metrics  : AVG(Cost)    Time Range : No filter
แท็บ Advanced Analytics ▸ Rolling Window
  Rolling Function : mean    Periods : 7
  Min Periods      : 7        <-- ช่องที่คนข้ามบ่อยที่สุด
```



จดไว้ก่อน ว่าเส้นดิบหน้าตาเป็นอย่างไร



เส้นเรียบขึ้น เห็นแนวโน้มชัด แต่จุดสูงสุดจริงถูกกลบหายไป

ทำไม Min Periods ถึงสำคัญ

เส้นช่วงต้นที่หลอกตา

ไม่ตั้ง Min Periods

วันแรกเฉลี่ยจากข้อมูล **1 วัน** วันที่สองจาก **2 วัน** ไล่ไปจนครบ 7
แต่ถูกวาดด้วยเส้นแบบเดียวกันเป๊ะกับส่วนที่ครบ
คนอ่านแยกไม่ออกว่าตรงไหนเชื่อได้

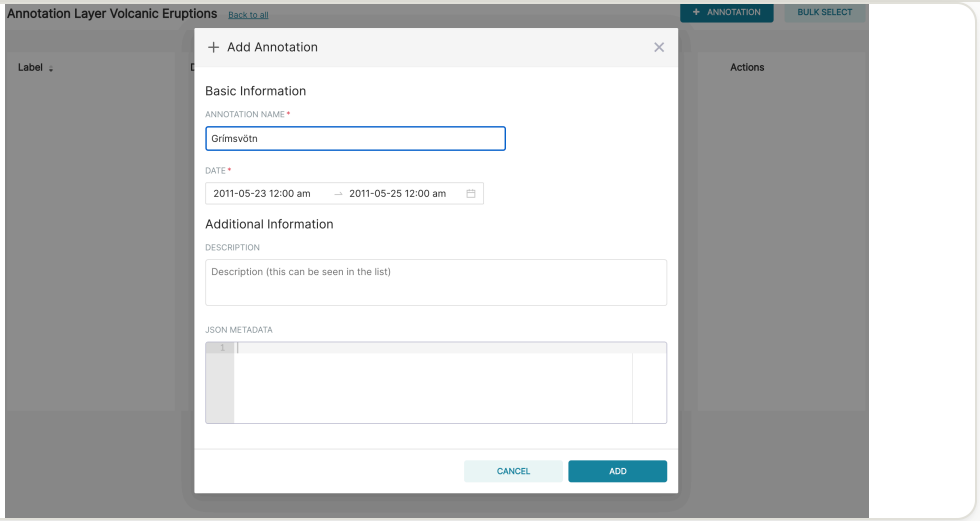
ตั้ง Min Periods = 7

ช่วงที่ข้อมูลไม่ครบ **หายไปจากกราฟ**
คนอ่านจึงไม่มีทางเผลออ่านค่าที่ยังคำนวณไม่ครบ
ระบบตรวจเช็กช่องนี้

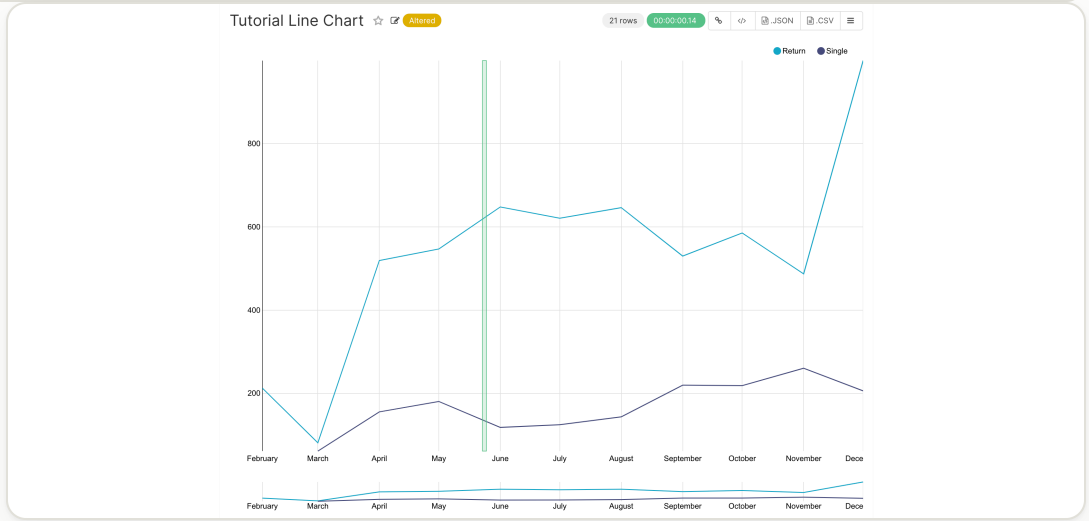
ตอนที่ 2

Annotation ที่ตั้งชื่อแล้ว

```
แท็บ Annotations and Layers ▸ Add annotation layer
  Name  : เส้นเป้าหมายค่าตั๋วเฉลี่ย 1,500 ปอนด์    <-- ระบบตรวจเช็กช่องนี้
  Type  : Formula
  Value : y=1500
  Style : Dashed
```



ตั้งชนิดเป็น `Formula` แล้วใส่ `y=1500` เพื่อลากเส้นแนวนอน



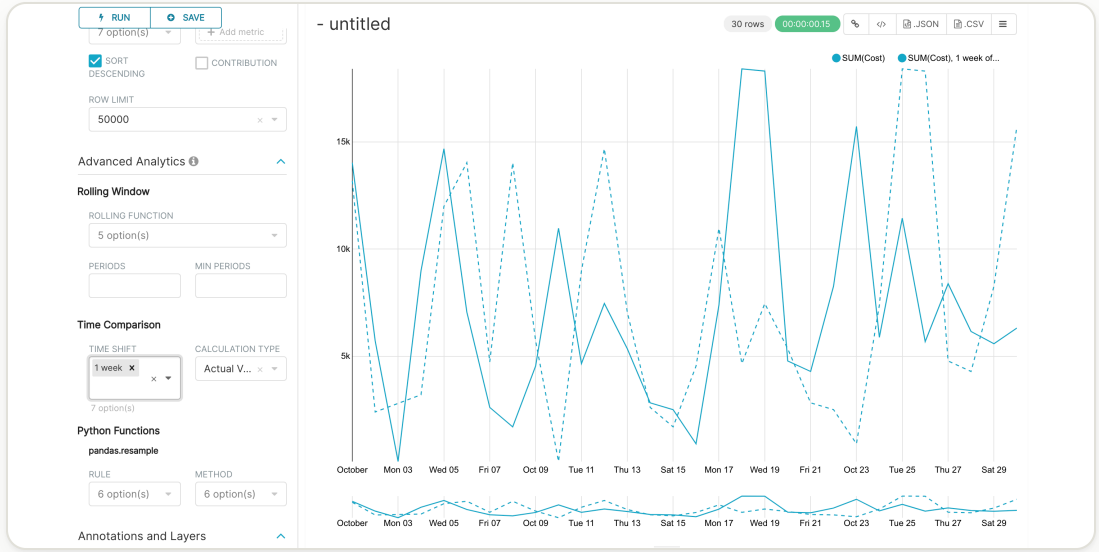
เส้นประที่ไม่มีชื่อ คือเส้นที่คนอ่านต้องเดาว่ามันคืออะไร

ตอนที่ 3 · ค่าที่ต้องกรอก

เทียบกับช่วงก่อนหน้า

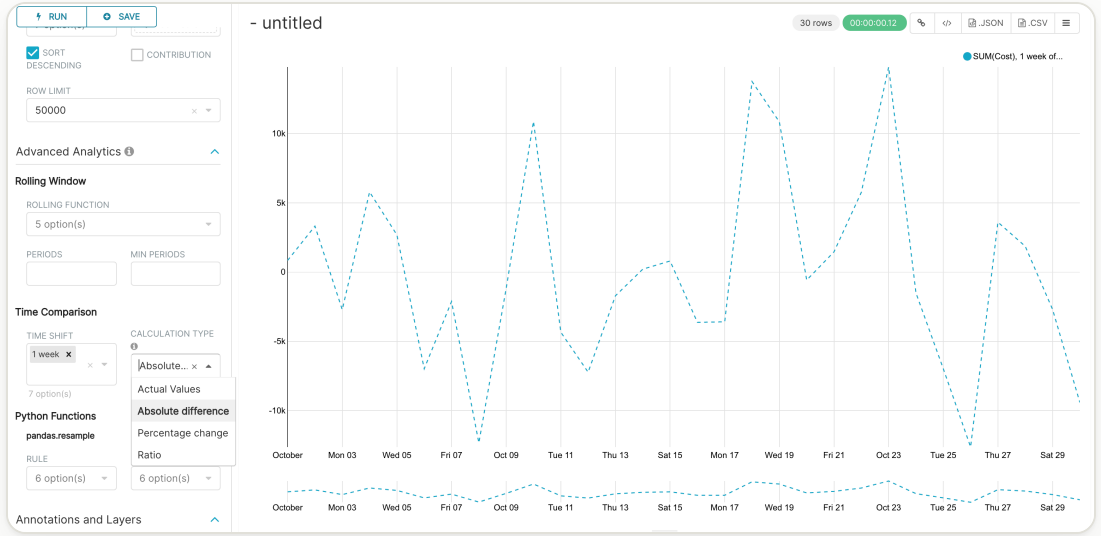
```
กราฟใหม่ Line Chart · Time Grain: Month · AVG(Cost)
แท็บ Advanced Analytics
  Time Comparison ▸ Time Shift : 30 days ago
  Time Comparison ▸ Calculation Type : Difference
  Resample ▸ Rule : 1 day    Fill Method : median
```

ACTUAL VALUES



วาดสองเส้นให้เทียบเอง

DIFFERENCE



วาดเฉพาะส่วนต่าง เหนือศูนย์คือโตขึ้น

ที่ช่อง Resample เลือก **`median`** เพราะทนต่อค่าผิดปกติได้ดีกว่า `mean`

Challenge · 5 นาที

Rolling ที่หลอกตัวเอง

ลองตั้ง **Periods เป็น 30** แล้วดูว่าเหลือเส้นให้ดูกี่ส่วน
การเลือกช่วงให้ยาวขึ้นได้อะไร และเสียอะไร

ตอนที่ 4 · สำรวจข้อมูลขั้นที่ 3 · 30 นาที

ควอร์ไทล์จาก SQL เทียบกับหนวดของ Box Plot

```
SELECT AIRLINE, COUNT(*) AS flights,
       MAX(CASE WHEN q = 1 THEN DEPARTURE_DELAY END) AS q1,
       MAX(CASE WHEN q = 2 THEN DEPARTURE_DELAY END) AS median,
       MAX(CASE WHEN q = 3 THEN DEPARTURE_DELAY END) AS q3
FROM (SELECT AIRLINE, DEPARTURE_DELAY, NTILE(4) OVER (PARTITION BY AIRLINE ORDER BY DEPARTURE_DELAY) AS q
      FROM flights WHERE DEPARTURE_DELAY IS NOT NULL)
GROUP BY AIRLINE ORDER BY median                        -- บันทึกชื่อ eda7_outlier_<รหัส>
```

คำนวณเอง: **ขอบบน = Q3 + 1.5 × (Q3 – Q1)** → AA ควรได้ 79.5 · VX ควรได้ 18.5

```
Box Plot  metric : DEPARTURE_DELAY   Distribute across : AIRLINE   Whisker : Tukey   Time Range : No filter
```

ค่าจากสองเครื่องมือควรตรงกันหรือต่างไม่เกิน 1 นาที · **สิ่งที่กราฟให้แต่ SQL ไม่ให้:** เห็น 14 สายพร้อมกันว่ากล่องไหนสูง กล่องไหนแคบ

ตอนที่ 4 · ของจริงหรือข้อมูลผิด

ยี่สิบเที่ยวที่ช้าที่สุด

```
Table  คอลัมน์ : AIRLINE · ORIGIN_AIRPORT · DESTINATION_AIRPORT · ds · DEPARTURE_DELAY · ARRIVAL_DELAY
  เรียง DEPARTURE_DELAY มาก→น้อย   Row limit : 20      ชื่อกราฟ : 20 เที่ยวที่ช้าที่สุด <รหัส>
```

ตรวจอะไร	ถ้าใช่ แปลว่า
`ARRIVAL_DELAY` ใกล้เคียง `DEPARTURE_DELAY` ในแถวเดียวกัน	ของจริง — สองคอลัมน์บันทึกแยกกันแต่ตรงกัน
สลับ Whisker เป็น Min/max หรือ Percentile 2/98 แล้วจุดหายไป	outlier ขึ้นกับนิยาม

Decision log สัปดาห์ 7: delay > 180 นาที 557 เที่ยวเป็นของจริง → เก็บไว้ทั้งหมดแต่ทำเครื่องหมาย ไม่ลบ ไม่ตัดเพดาน · เทียบข้ามสายด้วย median

ส่งงาน

เกณฑ์คะแนน

ข้อ	คะแนน
ชื่อแดชบอร์ดถูกรูปแบบ เปิดได้ ยังเป็น Draft	2
งานสัปดาห์ 2 ถึง 6 ยังอยู่ครบ	2
rolling mean 7 วัน + min periods · time comparison · resample · annotation ที่ตั้งชื่อ	4
คุณภาพของบันทึก — มีตัวเลขหรือชื่อค่าจากข้อมูล และยาวพอ	2

กด "ลองตรวจ" แล้ว "ส่งงาน" ที่ `spu.minddatatech.com/assignment` · ไม่ต้อง export ไฟล์ · ห้าม Publish