

Lab 7 · 110 นาที · สัปดาห์ที่ 7

คำนวณเพิ่มจากผลลัพธ์ โดยไม่ต้องเขียน SQL

Rolling Window · Time Comparison · Resample · Annotation Layers

ทุกอย่างวันนี้อยู่ในแท็บ **Advanced Analytics** ของหน้า Explore

วันนี้ทำอะไร

สามช่วง บวก Challenge

ตอน	ทำอะไร	เวลา
1	ค่าเฉลี่ยเคลื่อนที่ 7 วัน พร้อม Min Periods	35 น.
2	Annotation Layer ที่ ตั้งชื่อแล้ว	20 น.
3	Time Comparison + Resample	35 น.
4	Challenge — ลอง Periods 30 แล้วดูว่าเหลือเส้นเท่าไร	20 น.

ตอนที่ 1 · ค่าที่ต้องกรอก

เฉลี่ยเคลื่อนที่ 7 วัน


ชนิดกราฟ : Line Chart X-axis : Travel Date Time Grain : Day

Metrics : AVG(Cost) Time Range : No filter


เห็น Advanced Analytics ▸ Rolling Window

Rolling Function : mean Periods : 7

Min Periods : 7 <-- ช่องที่คนข้ามบ่อยที่สุด



จดไว้ก่อน ว่าเส้นดิบหน้าตาเป็นอย่างไร



เส้นเรียบขึ้น เห็นแนวโน้มชัด แต่จุดสูงสุดจริงถูกกลบหายไป

ทำไม Min Periods ถึงสำคัญ

เส้นช่วงต้นที่หลอกตา

ไม่ตั้ง Min Periods

วันแรกเฉลี่ยจากข้อมูล **1 วัน** วันที่สองจาก **2 วัน** ไปจนครบ 7
แต่ถูกวาดด้วยเส้นแบบเดียวกันเป๊ะกับส่วนที่ครบ
คนอ่านแยกไม่ออกว่าตรงไหนเชื่อได้

ตั้ง Min Periods = 7

ช่วงที่ข้อมูลไม่ครบ หายไปจากกราฟ
คนอ่านจึงไม่มีทางเผลออ่านค่าที่ยังคำนวณไม่ครบ
ระบบตรวจเช็คช่องนี้

ตอนที่ 2

Annotation ที่ตั้งชื่อแล้ว


แท็บ Annotations and Layers ▸ Add annotation layer

Name : เส้นเป้าหมายค่าตัวเฉลี่ย 1,500 ปอนด์ <-- ระบบตรวจเช็คช่องนี้


Type : Formula

Value : $y=1500$

Style : Dashed



ตั้งชนิดเป็น Formula แล้วใส่ $y=1500$ เพื่อลากเส้นแนวนอน




เส้นประที่ไม่มีชื่อ คือเส้นที่คนอ่านต้องเดาว่ามันคืออะไร

ตอนที่ 3 · ค่าที่ต้องกรอก

เทียบกับช่วงก่อนหน้า


กราฟใหม่ Line Chart · Time Grain: Month · AVG(Cost)
แท็บ Advanced Analytics
Time Comparison ▸ Time Shift : 1 year ago
Time Comparison ▸ Calculation Type : Difference
Resample ▸ Rule : 1 day Fill Method : median

ACTUAL VALUES



วาดสองเส้นให้เทียบเอง
ที่ช่อง Resample เลือก **median** เพราะทนต่อค่าผิดปกติได้ดีกว่า **mean**

DIFFERENCE



วาดเฉพาะส่วนต่าง เหนือศูนย์คือโตขึ้น

เกณฑ์คะแนน

ข้อ	คะแนน
ชื่อแดชบอร์ดถูกรูปแบบ เปิดได้ ยังเป็น Draft	2
งานสัปดาห์ 2 ถึง 6 ยังอยู่ครบ	2
rolling mean 7 วัน + min periods · time comparison · resample · annotation ที่ตั้งชื่อ	4
คุณภาพของบันทึก — มีตัวเลขหรือข้อความจากข้อมูล และยาวพอ	2

Challenge ลองตั้ง Periods เป็น 30 แล้วดูว่าเหลือเส้นให้ดูกี่ส่วน การเลือกช่วงให้ยาวขึ้นได้อะไร และเสียอะไร

ตอนที่ 4 · สํารวจข้อมูลขั้นที่ 3 · 30 นาที

ควอร์ไท์จาก SQL เทียบกับขนาดของ Box Plot

```
SELECT AIRLINE, COUNT(*) AS flights,  
       MAX(CASE WHEN q = 1 THEN DEPARTURE_DELAY END) AS q1,  
       MAX(CASE WHEN q = 2 THEN DEPARTURE_DELAY END) AS median,  
       MAX(CASE WHEN q = 3 THEN DEPARTURE_DELAY END) AS q3  
FROM (SELECT AIRLINE, DEPARTURE_DELAY, NTILE(4) OVER (PARTITION BY AIRLINE ORDER BY DEPARTURE_DELAY) AS q  
      FROM flights WHERE DEPARTURE_DELAY IS NOT NULL)  
GROUP BY AIRLINE ORDER BY median -- บันทึกชื่อ eda7_outlier_<รหัส>
```

คำนวณเอง: $\text{ขอบบน} = Q3 + 1.5 \times (Q3 - Q1) \rightarrow \text{AA ควรได้ } 79.5 \cdot \text{VX ควรได้ } 18.5$

Box Plot metric : DEPARTURE_DELAY Distribute across : AIRLINE Whisker : Tukey Time Range : No filter

ค่าจากสองเครื่องมือควรตรงกันหรือต่างไม่เกิน 1 นาที · **สิ่งที่กราฟให้แต่ SQL ไม่ให้:** เห็น 14 สายพร้อมกันว่ากล่องไหนสูง กล่องไหนแคบ

ตอนที่ 4 · ของจริงหรือข้อมูลผิด

ยี่สิบเที่ยวที่ช้าที่สุด

Table คอลัมน์ : AIRLINE · ORIGIN_AIRPORT · DESTINATION_AIRPORT · ds · DEPARTURE_DELAY · ARRIVAL_DELAY
เรียง DEPARTURE_DELAY มาก→น้อย Row limit : 20 ชื่อกราฟ : 20 เที่ยวบินที่ช้าที่สุด <รหัส>

ตรวจสอบอะไร	ถ้าใช่ แปลว่า
ARRIVAL_DELAY ใกล้เคียง DEPARTURE_DELAY ในแถวเดียวกัน	ของจริง — สองคอลัมน์บันทึกแยกกันแต่ตรงกัน
สลับ Whisker เป็น Min/max หรือ Percentile 2/98 แล้วจุดหายไป	outlier ขึ้นกับนิยาม

Decision log สัปดาห์ 7: delay > 180 นาที 557 เที่ยวบินเป็นของจริง → เก็บไว้ทั้งหมดแต่ทำเครื่องหมาย ไม่ลบ ไม่ตัดเพดาน · เทียบข้ามสายด้วย median