

Lab 8 · 110 นาที · สัปดาห์ที่ 8

สรุปในฐานข้อมูล แล้วเลิกเขียนสูตรซ้ำ

ครั้งแรกคือ SQL Lab ครั้งหลังคือการย้ายสูตรที่เขียนซ้ำมาหกลำดับ ไปไว้ที่เดียว

ลองนับดูว่ากราฟบนแดชบอร์ดของคุณ ใช้ `AVG (Cost)` อยู่กี่รูป

วันนี้ทำอะไร

สามช่วง บวก Challenge

ตอน	ทำอะไร	เวลา
1	เขียน SQL ที่สรุปข้อมูล แล้วนับว่าเหลือกี่แถว	35 น.
2	Save dataset แล้วสร้างกราฟจาก Dataset เสมือน	25 น.
3	นิยาม metric กลางที่ Dataset	35 น.
4	Challenge — เมื่อไรใช้ SQL Lab เมื่อไรใช้ Explore	15 น.

ตอนที่ 1 · คำสั่งที่ต้องพิมพ์

SQL ที่สรุปข้อมูลก่อนส่งมาวาด

```
-- SQL ▶ SQL Lab   Database: examples   Schema: public
SELECT DATE_TRUNC('month', "Travel Date") AS "เดือน",
       "Travel Class"                      AS "ชั้นโดยสาร",
       AVG("Cost")                        AS "ค่าตัวเฉลี่ย",
       COUNT(*)                          AS "จำนวนเที่ยว"
FROM tutorial_flights
GROUP BY 1, 2
ORDER BY 1
```

จดลงใบงาน ผลลัพธ์ได้กี่แถว · ข้อมูลดิบมีกี่แถว · ลดลงกี่เท่า
ข้อมูลที่ไม่ต้องเดินทางผ่านเครือข่าย คือข้อมูลที่มาถึงเร็ว

ตอนที่ 2 · จุดที่พลาดมากที่สุด

กด Run เฉย ๆ ไม่พอ

การรัน SQL ทิ้งไว้ ไม่ได้ติดไปกับไฟล์ export

ต้องกด **Save > Save dataset** ตั้งชื่อ

ถ้าไม่กด ระบบตรวจจะไม่เห็นงานส่วนนี้เลย และคุณจะต้องทำซ้ำที่หน้าแรก

เปิด Dataset เสมือนที่เพิ่งสร้าง แล้วทำกราฟ

ชนิดกราฟ : Line Chart

X-axis : เดือน

Metrics : AVG(ค่าตัวเฉลี่ย)

Dimensions : ชั้นโดยสาร

X / Y Axis Title : เดือน / ค่าตัวเฉลี่ย (ปอนด์)

ตั้งชื่อ : ค่าตัวเฉลี่ยรายเดือนจาก SQL Lab <รหัส>

บันทึกลงแดชบอร์ด csi414_<รหัส> แท็บเจาะลึก

ตอนที่ 3 · ค่าที่ต้องกรอก

metric กลางที่ Dataset

Datasets ▸ tutorial_flights ▸ ไอคอนดินสอ ▸ แท็บ Metrics ▸ Add item


Metric Key : ค่าตัวเฉลี่ย

Label : ค่าตัวเฉลี่ย (ปอนด์)

SQL Expression : AVG("Cost")

D3 Format : ,.1f

Description : นับทุกเที่ยว ไม่ตัดตัวที่ยกเลิก



แล้วกลับไปแก้กราฟเดิมอย่างน้อย 1 รูป

ให้เลือก metric **ค่าตัวเฉลี่ย (ปอนด์)** จากรายการ แทนที่จะสร้าง
adhoc metric ใหม่

วันที่นิยามต้องเปลี่ยน คุณจะแก้ที่เดียวจบ

metric ที่นิยามตรงนี้ จะไปโผล่ในรายการของทุกกราฟที่ใช้ Dataset นี้

เมื่อไรใช้อะไร

สถานการณ์	ใช้อะไร
ต้องรวมข้อมูลจากหลายตาราง	SQL Lab
ต้องคำนวณที่ Superset ไม่มีให้	SQL Lab
อยากลองเปลี่ยนมุมมองเร็ว ๆ ห้ารอบ	Explore
คนที่ใช้ต่อเขียน SQL ไม่เป็น	Explore บน Dataset ที่เตรียมไว้ให้
ข้อ	คะแนน
ชื่อแดชบอร์ดถูกรูปแบบ เปิดได้ ยังเป็น Draft	2
งานสัปดาห์ 2 ถึง 7 ยังอยู่ครบ	2
Dataset เสมือนมี GROUP BY และฟังก์ชันรวม · มีกราฟจาก Dataset นั้น · มี metric กลาง	4
คุณภาพของบันทึก — มีตัวเลขหรือข้อความจากข้อมูล และยาวพอ	2

ตอนที่ 4 · สํารวจข้อมูลขั้นที่ 4 · 30 นาที

ร้านค้าของเดิม แล้วถามสองข้อที่กราฟตอบไม่ได้

Saved Query ของคุณ	ต้องได้เลขเดิม
eda5_ค่าหาย	ARRIVAL_DELAY หาย 1,354
eda6_การกระจาย	mean 16.8 · p50 = 2 · เกิน 180 นาที = 557
eda7_outlier	ขอบบนของ AA = 79.5
<pre>SELECT COUNT(*) AS rows_all, COUNT(DISTINCT ds AIRLINE FLIGHT_NUMBER ORIGIN_AIRPORT) AS rows_unique FROM flights;</pre> -- (1) มีแถวซ้ำใหม่: ควรได้ 55,105 ทั้งคู่	
(2) ค่าสัมพันธ์ r ระหว่าง delay ขาออกกับขาเข้า — SQLite ไม่มี corr() จึงคำนวณจากสูตรในใบงาน ควรได้ราว 0.95 · บันทึกชื่อ eda8_ตรวจซ้ำ_<รหัส>	

ตอนที่ 4 · Dataset เสร็จแล้วของคุณเอง

flights_clean_<รหัส> และ metric กลาง

SQL Lab ▸ วาง SQL จากใบงาน ▸ Run ▸ Save ▾ ▸ Save dataset

ชื่อ : flights_clean_<รหัสนักศึกษา> ต้องเหลือ 53,751 แถว

Datasets ▸ flights_clean_<รหัส> ▸ Edit ▸ Metrics ▸ + Add item

Metric : on_time_rate SQL expression : AVG(1 - is_delayed)

ตรวจสอบผล	ควรได้
Table on_time_rate ตาม AIRLINE เรียงมาก→น้อย	VX นำราว 86% · MQ รั้งท้ายราว 47%
is_outlier = 1	552 แถว (ไม่ใช่ 557 — อีก 5 เทียวยหายไป WHERE)

Dataset นี้ **เห็นได้เฉพาะคุณ** · ตั้งแต่สัปดาห์หน้า ทุกกราฟในแท็บสำรวจข้อมูลต้องใช้ flights_clean เท่านั้น