Lab 8 · 110 นาที · สัปดาห์ที่ 8

สรุปในฐานข้อมูล แล้วเลิกเขียนสูตรซ้ำ

ครึ่งแรกคือ SQL Lab ครึ่งหลังคือการย้ายสูตรที่เขียนซ้ำมาหกสัปดาห์ ไปไว้ที่เดียว

ลองนับดูว่ากราฟบนแดชบอร์ดของคุณ ใช้ `AVG(Cost)` อยู่กี่รูป

วันนี้ทำอะไร

สามช่วง บวก Challenge

ตอน	ทำอะไร	เวลา
1	เขียน SQL ที่สรุปข้อมูล แล้วนับว่าเหลือกี่แถว	35 น.
2	**Save dataset** แล้วสร้างกราฟจาก Dataset เสมือน	25 น.
3	นิยาม metric กลางที่ Dataset	35 น.
4	Challenge — เมื่อไรใช้ SQL Lab เมื่อไรใช้ Explore	15 น.

ตอนที่ 1 · คำสั่งที่ต้องพิมพ์

SQL ที่สรุปข้อมูลก่อนส่งมาวาด

```
-- SQL ▸ SQL Lab   Database: lab_db   Schema: public
SELECT DATE_TRUNC('month', "Travel Date") AS "เดือน",
       "Travel Class"                     AS "ชั้นโดยสาร",
       AVG("Cost")                        AS "ค่าตั๋วเฉลี่ย",
       COUNT(*)                           AS "จำนวนเที่ยว"
FROM tutorial_flights
GROUP BY 1, 2
ORDER BY 1
```

จดลงใบงาน ผลลัพธ์ได้กี่แถว · ข้อมูลดิบมีกี่แถว · ลดลงกี่เท่า
ข้อมูลที่ไม่ต้องเดินทางผ่านเครือข่าย คือข้อมูลที่มาถึงเร็ว

ตอนที่ 2 · จุดที่พลาดมากที่สุด

กด Run เฉย ๆ ไม่พอ

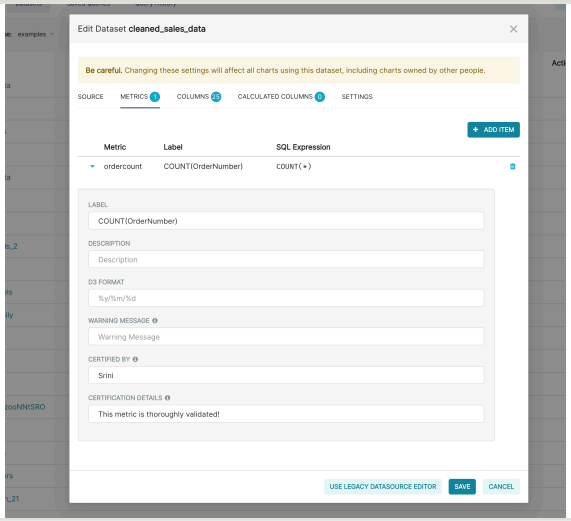
การรัน SQL ทิ้งไว้ไม่ติดไปกับไฟล์ export
ต้องกด **Save ▸ Save dataset** ตั้งชื่อ `สรุปค่าตั๋วรายเดือน <รหัส>`
ถ้าไม่กด ระบบตรวจจะไม่เห็นงานส่วนนี้เลย และคุณจะตกทั้งที่ทำแล้ว

```
เปิด Dataset เสมือนที่เพิ่งสร้าง แล้วทำกราฟ
  ชนิดกราฟ   : Line Chart
  X-axis      : เดือน
  Metrics     : AVG(ค่าตั๋วเฉลี่ย)
  Dimensions  : ชั้นโดยสาร
  X / Y Axis Title : เดือน / ค่าตั๋วเฉลี่ย (ปอนด์)
ตั้งชื่อ : ค่าตั๋วเฉลี่ยรายเดือนจาก SQL Lab <รหัส>
บันทึกลงแดชบอร์ด csi414_<รหัส> แท็บเจาะลึก
```

ตอนที่ 3 · ค่าที่ต้องกรอก

metric กลางที่ Dataset

```
Datasets ▸ tutorial_flights ▸ ไอคอนดินสอ ▸ แท็บ Metrics ▸ Add item
  Metric Key      : ค่าตั๋วเฉลี่ย
  Label           : ค่าตั๋วเฉลี่ย (ปอนด์)
  SQL Expression  : AVG("Cost")
  D3 Format       : ,.1f
  Description     : นับทุกเที่ยว ไม่ตัดตั๋วที่ยกเลิก
```



metric ที่นิยามตรงนี้ จะไปโผล่ในรายการของทุกกราฟที่ใช้ Dataset นี้

แล้วกลับไปแก้กราฟเดิมอย่างน้อย 1 รูป

ให้เลือก metric `ค่าตั๋วเฉลี่ย (ปอนด์)` จากรายการ แทนที่จะสร้าง adhoc metric ใหม่

วันที่นิยามต้องเปลี่ยน คุณจะแก้ที่เดียวจบ

Challenge และส่งงาน

เมื่อไรใช้อะไร

สถานการณ์	ใช้อะไร
ต้องรวมข้อมูลจากหลายตาราง	SQL Lab
ต้องคำนวณที่ Superset ไม่มีให้	SQL Lab
อยากลองเปลี่ยนมุมมองเร็ว ๆ ห้ารอบ	Explore
คนที่ใช้ต่อเขียน SQL ไม่เป็น	Explore บน Dataset ที่เตรียมไว้ให้

ข้อ	คะแนน
ชื่อแดชบอร์ดถูกรูปแบบ เปิดได้ ยังเป็น Draft	2
งานสัปดาห์ 2 ถึง 7 ยังอยู่ครบ	2
Dataset เสมือนมี GROUP BY และฟังก์ชันรวม · มีกราฟจาก Dataset นั้น · มี metric กลาง	4
คุณภาพของบันทึก — มีตัวเลขหรือชื่อค่าจากข้อมูล และยาวพอ	2

กด "ลองตรวจ" แล้ว "ส่งงาน" ที่ `spu.minddatatech.com/assignment` · ไม่ต้อง export ไฟล์ · ห้าม Publish

ตอนที่ 4 · สำรวจข้อมูลขั้นที่ 4 · 30 นาที

รันซ้ำของเดิม แล้วถามสองข้อที่กราฟตอบไม่ได้

Saved Query ของคุณ	ต้องได้เลขเดิม
`eda5_ค่าหาย`	`ARRIVAL_DELAY` หาย 1,354
`eda6_การกระจาย`	mean 16.8 · p50 = 2 · เกิน 180 นาที = 557
`eda7_outlier`	ขอบบนของ AA = 79.5

```
SELECT COUNT(*) AS rows_all,                                        -- (1) มีแถวซ้ำไหม: ควรได้ 55,105 ทั้งคู่
       COUNT(DISTINCT ds || AIRLINE || FLIGHT_NUMBER || ORIGIN_AIRPORT) AS rows_unique
FROM flights;
```

(2) ค่าสัมพันธ์ r ระหว่าง delay ขาออกกับขาเข้า — SQLite ไม่มี `corr()` จึงคำนวณจากสูตรในใบงาน ควรได้ราว **0.95** · บันทึกชื่อ `eda8_ตรวจซ้ำ_<รหัส>`

ตอนที่ 4 · Dataset เสมือนของคุณเอง

`flights_clean_<รหัส>` และ metric กลาง

```
SQL Lab  ▸  วาง SQL จากใบงาน  ▸  Run  ▸  Save ▾  ▸  Save dataset
  ชื่อ : flights_clean_<รหัสนักศึกษา>                          ต้องเหลือ 53,751 แถว
Datasets  ▸  flights_clean_<รหัส>  ▸  Edit  ▸  Metrics  ▸  + Add item
  Metric : on_time_rate        SQL expression : AVG(1 - is_delayed)
```

ตรวจผล	ควรได้
Table `on_time_rate` ตาม `AIRLINE` เรียงมาก→น้อย	VX นำราว 86% · MQ รั้งท้ายราว 47%
`is_outlier` = 1	**552** แถว (ไม่ใช่ 557 — อีก 5 เที่ยวหายไปที่ `WHERE`)

> Dataset นี้ **เห็นได้เฉพาะคุณ** · ตั้งแต่สัปดาห์หน้า ทุกกราฟในแท็บสำรวจข้อมูลต้องใช้ `flights_clean` เท่านั้น