

Lab 9 · 110 นาที · สัปดาห์ที่ 9

สองแสนจุดต้องอ่านออก ไม่ใช่แค่ชินครบ

Dataset วันนี้เปลี่ยนเป็น `san_francisco` — ที่อยู่ในเมือง 261,552 แถว

ทำไมถึงเปลี่ยนชุดข้อมูล: `tutorial_flights` มีพิกัดสนามบินแค่ 113 จุดที่ไม่ซ้ำกัน ซึ่งเป็นคนละปัญหากับจุดทับกันจริง

วันนี้ทำอะไร

สามช่วง บวก Challenge

ตอน	ทำอะไร	เวลา
1	จุดติบด้วย deck.gl Scatterplot	30 น.
2	รวมจุดด้วย deck.gl Grid หรือ Hexagon	35 น.
3	เขียนอธิบายวิธีอ่านแผนที่ลงกล่อง Markdown	20 น.
4	Challenge — ความหนาแน่นของจุดแทนอะไรกันแน่	25 น.

ตอนที่ 1 · คำที่ต้องกรอก

จุดติดบนแผนที่

```
Dataset      : san_francisco
ชนิดกราฟ    : deck.gl Scatterplot
Longitude & Latitude : latitude/longitude columns
  Latitude    : LAT          <-- ค่าอยู่ระหว่าง -90 ถึง 90
  Longitude   : LON          <-- ค่าอยู่ระหว่าง -180 ถึง 180
Time Range   : No filter
Row limit    : 10000 ก่อน แล้วค่อยเพิ่มเป็น 100000
```

ความผิดพลาดอันดับหนึ่ง คือใส่สองช่องนี้สลับกัน

จุดทั้งหมดจะไปโผล่กลางมหาสมุทรอินเดีย เพราะละติจูด 122 ไม่มีอยู่จริง


ระบบจะไม่ฟ้อง มันจะวาดให้ตามที่สั่ง — ระบบตรวจของแล็บนี้จับความผิดพลาดนี้ด้วย

จดลงใบงาน แต่ละ Row limit ใช้เวลาโหลดกี่วินาที และตรงกลางเมืองยังนับจุดได้ไหม

รวมจุดให้อ่านออก


จุดดิบ

ตรงกลางทับกันจนบอกไม่ได้ว่ามีกี่จุด



รวมจุดเป็นช่อง

ความเข้มบอกจำนวนจุดในช่องนั้น



ทั้งสองภาพคือข้อมูลชุดเดียวกัน การลดความทึบของจุดไม่ได้แก้ปัญหานี้ เพราะปัญหาอยู่ที่ยังไม่ได้รวมข้อมูล ไม่ได้อยู่ที่สี

วิธีที่มักลองก่อน

ลดความทึบของจุด

ลดขนาดจุด

เปลี่ยนสี

ทำไมไม่ได้ผล

พองจุดทับกันสีบชั้นก็ทึบเหมือนเดิม

อ่านตำแหน่งยากขึ้น แต่ตรงกลางยังนับไม่ได้

ไม่เกี่ยวกับปัญหาเลย

ตอนที่ 2 · ค่าที่ต้องกรอก

deck.gl Grid

ชนิดกราฟ : deck.gl Grid (หรือ Hexagon)
Latitude / Longitude : LAT / LON (เหมือนเดิม)
Metric : COUNT(*)
Grid size : ลองค่าเริ่มต้น แล้วลองเล็กลงและใหญ่ขึ้นอย่างละครึ่ง
ตั้งชื่อ : ความหนาแน่นของที่อยู่แบบรวมช่อง <รหัส>

ขนาดช่องเปลี่ยนข้อสรุปได้จริง

ช่องใหญ่เกินไปจะรวมพื้นที่ที่ไม่เกี่ยวข้องกันเข้าด้วยกัน จนดูเหมือนทั้งย่านหนาแน่นเท่ากัน ช่องเล็กเกินไปจะกลับไปเหมือนจุดดิบที่อ่านความหนาแน่นไม่ออก
ไม่มีขนาดที่ถูกเพียงขนาดเดียว ต้องเลือกให้เข้ากับคำถาม และบอกคนอ่านว่าเลือกเท่าไร

หัวใจของแล็บนี้

เพิ่มสามบรรทัดนี้ในกล่อง Markdown

1. สีเข้มหรือช่องสูง แปลว่าอะไร
2. ขนาดช่องที่เลือกไว้เท่าไร
3. ข้อมูลมาจากไหนและครอบคลุมอะไร

Challenge · ช่องที่เข้มที่สุดแปลว่ามีคนมากที่สุดจริงหรือ

แผนที่นี้แสดง ความหนาแน่นของที่อยู่ที่ถูกบันทึกไว้

ไม่ใช่ความหนาแน่นของประชากร — ตึกแถวหลังหนึ่งมีที่อยู่เดียวแต่มีคนอยู่ร้อยคน

ย่านตึกสูงจึงอาจดูว่างบนแผนที่ ทั้งที่คนแน่นที่สุดในเมือง

สิ่งที่แผนที่นับ กับสิ่งที่คนอ่านคิดว่ามันนับ มักไม่ใช่อันเดียวกัน

ตอนที่ 4 · สํารวจข้อมูลชั้นที่ 5 · 30 นาที

หา r ก่อน แล้วทายว่าจุดจะเรียงเป็นเส้นหรือเป็นก้อนเมฆ

```
SELECT ROUND((n*sxy - sx*sy) / sqrt((n*sxx - sx*sx) * (n*syy - sy*sy)), 3) AS r
FROM (SELECT COUNT(*) AS n, SUM(X*Y) AS sxy, SUM(X) AS sx, SUM(Y) AS sy, SUM(X*X) AS sxx, SUM(Y*Y) AS syy
      FROM flights WHERE CANCELLED = 0 AND DIVERTED = 0)      -- แทน X, Y ที่ละคู่ · บันทึกชื่อ eda9_ความสัมพันธ์_<รหัส>
```

คู่	r ควรได้ประมาณ
DISTANCE ~ AIR_TIME	0.98
DEPARTURE_DELAY ~ ARRIVAL_DELAY	0.95
DISTANCE ~ ARRIVAL_DELAY	0

SQL Lab เรียก Dataset เสมือนด้วยชื่อไม่ได้ จึงใส่เงื่อนไขเดียวกับ `flights_clean` ไว้ใน `WHERE`

ตอนที่ 4 · จุดต่อแถวจริง

Bubble Chart บน `flights_clean_<รหัส>`

```
Bubble Chart  Entity : id                                <-- หนึ่ง id = หนึ่งแถว (คอลัมน์ที่สร้างไว้สัปดาห์ 8)
  X : MAX(DISTANCE)  Y : MAX(AIR_TIME)  Bubble size : COUNT(*)      ต้องเป็น metric ทั้งคู่
  Filter : AIRLINE = 'VX'    (573 เที่ยวบิน)  Row limit : 1000  Time Range : No filter
```

กราฟ	ลงสีด้วย	สิ่งที่ต้องเขียน
delay ขาออก ~ ขาเข้า	<code>is_outlier</code>	รู้ทีหลัง ใช้ทำนายล่วงหน้าไม่ได้ (leakage)
เส้น <code>on_time_rate</code> ตาม <code>dep_hour</code>	—	ถึงเช้า 06:00 ≈ 20% → 21:00 ≈ 46% ทั้งที่ r แค่ 0.18

ชุด `flights` ดิบ **ไม่มี** คอลัมน์ `id` — Bubble ต้องทำบน `flights_clean` ของคุณเท่านั้น