Lab 9 · 110 นาที · สัปดาห์ที่ 9

สองแสนจุดต้องอ่านออก ไม่ใช่แค่ขึ้นครบ

Dataset วันนี้เปลี่ยนเป็น `san_francisco` — ที่อยู่ในเมือง 261,552 แถว

ทำไมถึงเปลี่ยนชุดข้อมูล: `tutorial_flights` มีพิกัดสนามบินแค่ 113 จุดที่ไม่ซ้ำกัน ซึ่งเป็นคนละปัญหากับจุดทับกันจริง

วันนี้ทำอะไร

สี่ช่วง บวก Challenge

ตอน	ทำอะไร	เวลา
1	จุดดิบด้วย deck.gl Scatterplot	25 น.
2	รวมจุดด้วย deck.gl Grid หรือ Hexagon	30 น.
3	เขียนอธิบายวิธีอ่านแผนที่ลงกล่อง Markdown	20 น.
	Challenge — ความหนาแน่นของจุดแทนอะไรกันแน่	5 น.
4	สำรวจข้อมูลขั้นที่ 5 — r และ Bubble Chart บน `flights_clean`	30 น.

ตอนที่ 1 · ค่าที่ต้องกรอก

จุดดิบบนแผนที่

```
Dataset    : san_francisco
ชนิดกราฟ   : deck.gl Scatterplot
Longitude & Latitude : Longitude & Latitude columns    (หน้าต่างเด้ง ส่วนบนสุด)
  Longitude : LON    ช่องซ้าย    <-- ค่าอยู่ระหว่าง -180 ถึง 180
  Latitude  : LAT    ช่องขวา     <-- ค่าอยู่ระหว่าง -90 ถึง 90
  ปุ่มบนแผงต้องขึ้นว่า  LON | LAT
Row limit   : 10000  ก่อน  แล้วค่อยเพิ่มเป็น 100000    (deck.gl ไม่มีช่อง Time Range)
```

ความผิดพลาดอันดับหนึ่ง คือใส่สองช่องนี้สลับกัน — Superset วาง Longitude ไว้ซ้าย ใครเลือกละติจูดก่อนตามความเคยชินจะสลับทันที
แผนที่จะว่างเปล่า ไม่มีจุดเลย เพราะละติจูด –122 ไม่มีอยู่จริง
ระบบจะไม่ฟ้อง มันจะวาดให้ตามที่สั่ง — **ระบบตรวจของแล็บนี้จับความผิดพลาดนี้ด้วย**

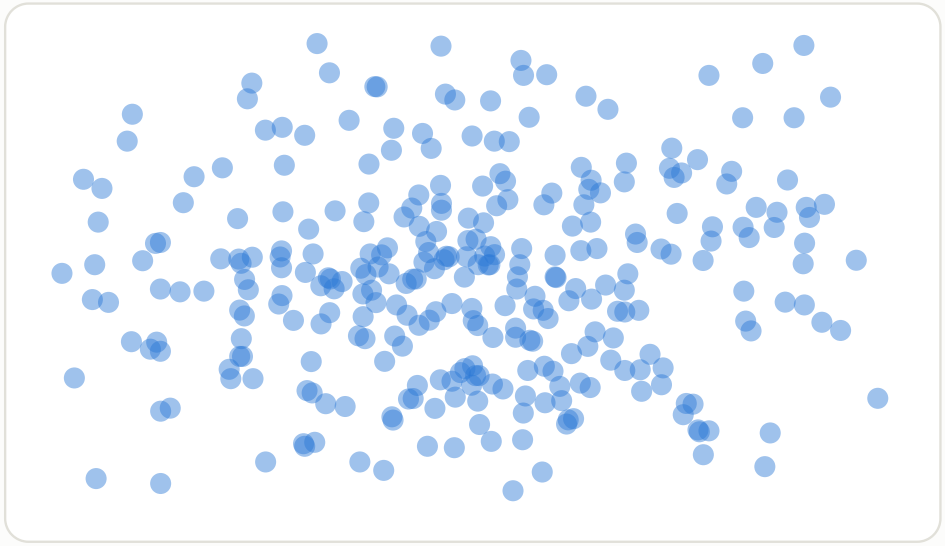
ไม่มีแผนที่พื้นหลัง และป้ายแดง `0 rows` บนกราฟ deck.gl เป็นเรื่องปกติของเซิร์ฟเวอร์วิชา ถ้าเห็นจุดก็ใช้ได้

จดลงใบงาน แต่ละ Row limit ใช้เวลาโหลดกี่วินาที และตรงกลางเมืองยังนับจุดได้ไหม

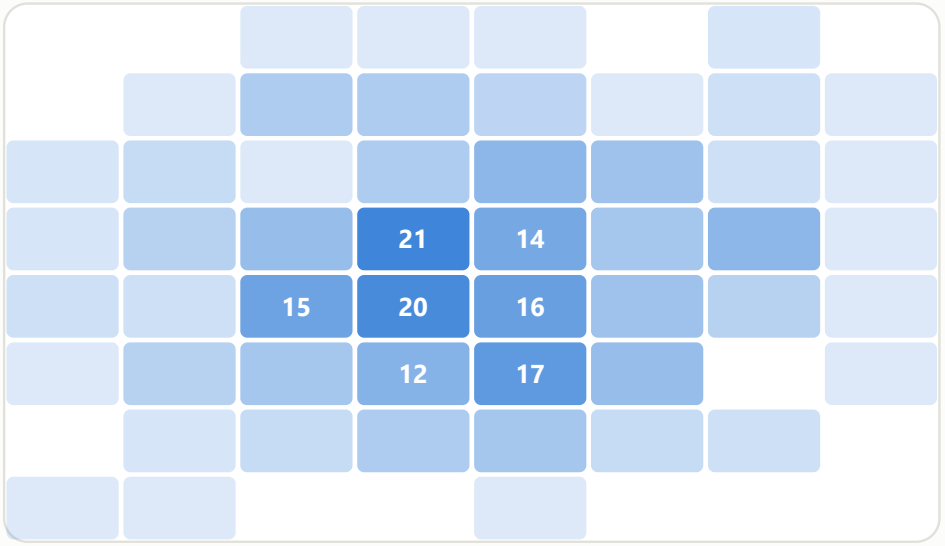
ตอนที่ 2

รวมจุดให้อ่านออก

จุดดิบ ตรงกลางทับกันจนบอกไม่ได้ว่ามีกี่จุด



รวมจุดเป็นช่อง ความเข้มบอกจำนวนจุดในช่องนั้น



ทั้งสองภาพคือข้อมูลชุดเดียวกัน **การลดความทึบของจุดไม่ได้แก้ปัญหานี้** เพราะปัญหาอยู่ที่ยังไม่ได้รวมข้อมูล ไม่ได้อยู่ที่สี

วิธีที่มักลองก่อน	ทำไมไม่ได้ผล
ลดความทึบของจุด	พอจุดทับกันสิบชั้นก็ทึบเหมือนเดิม
ลดขนาดจุด	อ่านตำแหน่งยากขึ้น แต่ตรงกลางยังนับไม่ได้
เปลี่ยนสี	ไม่เกี่ยวกับปัญหาเลย

ตอนที่ 2 · ค่าที่ต้องกรอก

deck.gl Grid

```
ชนิดกราฟ  : deck.gl Grid  (หรือ Hexagon)
Longitude & Latitude : LON | LAT     (เหมือนเดิม)
HEIGHT    : COUNT(*)      (Hexagon เรียกช่องนี้ว่า BUBBLE SIZE)
Row limit : 100000
Map → GRID SIZE (เมตร) : ลองค่าเริ่มต้น แล้วลองเล็กลงและใหญ่ขึ้นอย่างละครั้ง
Map → EXTRUDED ☑ · VIEWPORT → PITCH : 45   (เอียงให้เห็นเป็นแท่ง · หรือ Ctrl+ลากบนแผนที่)
ตั้งชื่อ   : ความหนาแน่นของที่อยู่แบบรวมช่อง <รหัส>
```

ขนาดช่องเปลี่ยนข้อสรุปได้จริง
ช่องใหญ่เกินไปจะรวมพื้นที่ที่ไม่เกี่ยวกันเข้าด้วยกัน จนดูเหมือนทั้งย่านหนาแน่นเท่ากัน ช่องเล็กเกินไปจะกลับไปเหมือนจุดดิบที่อ่านความหนาแน่นไม่ออก **ไม่มีขนาดที่ถูกเพียงขนาดเดียว** ต้องเลือกให้เข้ากับคำถาม และบอกคนอ่านว่าเลือกเท่าไร

ตอนที่ 3 และ Challenge

หัวใจของแล็บนี้

เพิ่มสามบรรทัดนี้ในกล่อง Markdown

1. สีเข้มหรือช่องสูง แปลว่าอะไร
2. ขนาดช่องที่เลือกไว้เท่าไร
3. ข้อมูลมาจากไหนและครอบคลุมอะไร

> **Challenge · ช่องที่เข้มที่สุดแปลว่ามีคนมากที่สุดจริงหรือ**
> แผนที่นี้แสดง **ความหนาแน่นของที่อยู่ที่ถูกบันทึกไว้**
> ไม่ใช่ความหนาแน่นของประชากร — **ตึกแถวหลังหนึ่งมีที่อยู่เดียวแต่มีคนอยู่ร้อยคน**
> ย่านตึกสูงจึงอาจดูจางบนแผนที่ ทั้งที่คนแน่นที่สุดในเมือง

สิ่งที่แผนที่นับ กับสิ่งที่คนอ่านคิดว่ามันนับ มักไม่ใช่อันเดียวกัน

ตอนที่ 4 · สำรวจข้อมูลขั้นที่ 5 · 30 นาที

หา r ก่อน แล้วทายว่าจุดจะเรียงเป็นเส้นหรือเป็นก้อนเมฆ

```
SELECT ROUND((n*sxy - sx*sy) / sqrt((n*sxx - sx*sx) * (n*syy - sy*sy)), 3) AS r
FROM (SELECT COUNT(*) AS n, SUM(X*Y) AS sxy, SUM(X) AS sx, SUM(Y) AS sy, SUM(X*X) AS sxx, SUM(Y*Y) AS syy
      FROM flights WHERE CANCELLED = 0 AND DIVERTED = 0)     -- แทน X, Y ทีละคู่ · บันทึกชื่อ eda9_ความสัมพันธ์_<รหัส>
```

คู่	r ควรได้ประมาณ
`DISTANCE` ~ `AIR_TIME`	0.98
`DEPARTURE_DELAY` ~ `ARRIVAL_DELAY`	0.95
`DISTANCE` ~ `ARRIVAL_DELAY`	0

> SQL Lab เรียก Dataset เสมือนด้วยชื่อไม่ได้ จึงใส่เงื่อนไขเดียวกับ `flights_clean` ไว้ใน `WHERE`

ตอนที่ 4 · จุดต่อแถวจริง

Bubble Chart บน `flights_clean_<รหัส>`

```
Bubble Chart   Entity : id                        <-- หนึ่ง id = หนึ่งแถว (คอลัมน์ที่สร้างไว้สัปดาห์ 8)
  X : MAX(DISTANCE)   Y : MAX(AIR_TIME)   Bubble size : COUNT(*)      ต้องเป็น metric ทั้งคู่
  Filter : AIRLINE = 'VX'   (573 เที่ยว)   Row limit : 1000
```

กราฟ	ลงสีด้วย	สิ่งที่ต้องเขียน
delay ขาออก ~ ขาเข้า	`is_outlier`	รู้ทีหลัง ใช้ทำนายล่วงหน้าไม่ได้ (leakage)
เส้น `on_time_rate` ตาม `dep_hour`	—	ถึงช้า 06:00 ≈ 20% → 21:00 ≈ 46% ทั้งที่ r แค่ 0.18

> ชุด `flights` ดิบ **ไม่มี** คอลัมน์ `id` — Bubble ต้องทำบน `flights_clean` ของคุณเท่านั้น

ส่งงาน

เกณฑ์คะแนน

ข้อ	คะแนน
ชื่อแดชบอร์ดถูกรูปแบบ เปิดได้ ยังเป็น Draft	2
งานสัปดาห์ 2 ถึง 8 ยังอยู่ครบ	2
แผนที่จุดดิบที่ตั้งพิกัดถูกช่อง · แผนที่แบบรวมจุด	4
คุณภาพของบันทึก — มีตัวเลขหรือชื่อค่าจากข้อมูล และยาวพอ	2

กด "ลองตรวจ" แล้ว "ส่งงาน" ที่ `spu.minddatatech.com/assignment` · ไม่ต้อง export ไฟล์ · ห้าม Publish