


สัปดาห์ที่ 2 • คู่มือบทที่ 6.1 ถึง 6.3

ก่อนวาดกราฟ ต้องรู้ก่อนว่าจะถามอะไร

วันนี้เพิ่มกราฟสองรูปแรกลงแดชบอร์ดที่คุณสร้างไว้แล้วเมื่อสัปดาห์ก่อน

ลำดับที่ห้ามข้าม

ห้าคำก่อนเตะเมสส์



คนที่เริ่มจากขั้นที่ 4 คือคนที่ทำกราฟสวยแล้วอธิบายไม่ได้ว่ามันตอบอะไร

ชั้นที่ 2 · ข้อมูล

ข้อมูลชุดนี้มาจากไหน

ที่มา

ที่เก็บทางการของโครงการเอง `apache-superset/examples-data`

เป็นชุดเดียวกับที่เอกสารทางการใช้ในบท *Exploring Data in Superset*
อาจารย์โหลดเข้าเซิร์ฟเวอร์ให้แล้ว บัญชีนักศึกษาไม่มีสิทธิ์อัปโหลดเอง

ตัวเลขที่ต้องจำ

2,954 แถว · 20 คอลัมน์

ช่วงเวลา **10 ก.พ.** ถึง **16 ธ.ค. 2011**

ค่าตัว **1.00** ถึง **7,969.20** ปอนด์

คำถามที่ต้องตอบก่อนนับอะไรทั้งสิ้น

หนึ่งแถวคืออะไร

การเดินทางด้วยเครื่องบิน **หนึ่งครั้ง** ของพนักงาน **หนึ่งคน** ในองค์กรแห่งหนึ่งในสหราชอาณาจักร

ประโยคนี้อบลงหน้าว่า `COUNT(*)` นับอะไร

นับ **จำนวนครั้งที่เดินทาง** ไม่ใช่จำนวนคน

พนักงานคนเดียวที่บินสิบครั้ง จะถูกนับสิบ — และข้อมูลชุดนี้ไม่มีทางแยกได้เลยว่าเป็นคนเดิมหรือคนละคน เพราะไม่มีชื่อและไม่มีรหัสพนักงาน

คอลัมน์ที่จะใช้วันนี้

เจ็ดคอลัมน์แรกจากทั้งหมด 20

คอลัมน์	ความหมาย	ค่าที่มี
Travel Date	วันที่เดินทาง	ก.พ. ถึง ธ.ค. 2011
Cost	ราคาตั๋ว หน่วยปอนด์	1.00 ถึง 7,969.20
Travel Class	ชั้นโดยสาร	4 ค่า
Ticket Single or Return	เที่ยวเดียวหรือไปกลับ	2 ค่า
Department	แผนกของพนักงาน	3 ค่า Yellow · Orange · Purple
Airline	สายการบิน	66 ค่า
Distance	ระยะทาง (กม.)	

อีก 13 คอลัมน์เป็นรายละเอียดต้นทางและปลายทาง · สายการบินคือ **Airline** ไม่ใช่ **Carrier**

ขั้นที่ 5 · คำอธิบาย เริ่มตั้งแต่ตอนนี้


สิ่ง que ข้อมูลชุดนี้ไม่ได้บอก

คนอ่านมักคิดว่ามันบอก	ความจริง
มีพนักงานกี่คนเดินทาง	ไม่มีตัวตนคนในข้อมูล นับได้แค่จำนวนครั้ง
การเดินทางนั้นคุ้มหรือไม่	ไม่มีผลลัพธ์ของการเดินทางเลยสักคอลัมน์
ภาพรวมทั้งปี 2011	ขาดมกราคมและปลายธันวาคม ใครสรุปว่าทั้งปีคือผิด
ราคาตัวเป็นแบบนี้	เป็นราคาปี 2011 · สิบห้าปีที่แล้ว

สื่บรรทัดนี้คือสิ่งที่ต้องเขียนลงกล่อง Markdown ไม่ใช่เก็บไว้ในหัวคนทำ

ขั้นที่ 3 · การรวมข้อมูล

กราฟทุกรูปคือการรวมข้อมูล



ข้อมูลดิบ 2,954 แถว กลายเป็นตาราง 4 บรรทัดได้ เพราะเราบอกระบบว่า **จัดกลุ่มด้วยอะไร** และ **รวมด้วยฟังก์ชันอะไร**

เลือกฟังก์ชันรวมให้ตรงคำถาม

COUNT กับ SUM ตอบคนละคำถาม

ฟังก์ชัน	ตอบคำถามว่า	ตัวอย่างจากข้อมูลชุดนี้
COUNT (*)	เกิดขึ้นกี่ครั้ง	แผนกไหน เดินทางบ่อย ที่สุด
SUM (Cost)	รวมแล้วเท่าไร	แผนกไหน ใช้เงิน มากที่สุด
AVG (Cost)	ต่อหนึ่งครั้งเท่าไร	ตัวใบนึง แพงแค่ไหน
MAX (Cost)	สูงสุดเท่าไร	ตัวที่แพงที่สุดที่เคยซื้อ

แผนกที่เดินทางบ่อยที่สุด กับแผนกที่ใช้เงินมากที่สุด มักไม่ใช่แผนกเดียวกัน
ถ้าเลือกฟังก์ชันผิด คำตอบที่ได้จะถูกตามสูตร แต่ผิดตามคำถาม

หน้าจอที่จะอยู่ด้วยไปอีกแปดสัปดาห์


ทัวร์หน้า Explore

สามแถบ

ซ้าย ชื่อ dataset และรายชื่อคอลัมน์

กลาง ชนิดกราฟ · แท็บ **Data** ใส่อะไรลงไป · แท็บ **Customize** หน้าตาเป็นยังไง

ขวา รูปกราฟ · แถบล่างสลับดู **Results** คือข้อมูลที่ได้กลับมาจริง



แท็บ **Data** กับ **Customize** อยู่บนสุดของแถบกลาง

สี่ช่องที่ใช้วันนี้

ช่องไหนทำอะไร

ช่อง	มันคืออะไร	วันนี้ตั้งเป็น
Query mode	สรุปข้อมูล หรือดูดิบทีละแถว	Aggregate ตลอด
Dimensions	จัดกลุ่มด้วยอะไร — หนึ่งค่าที่ต่างกัน เท่ากับหนึ่งบรรทัดในผลลัพธ์	Travel Class
Metrics	รวมด้วยฟังก์ชันอะไร ใส่ได้หลายตัวในช่องเดียว	COUNT(*) และ SUM(Cost)
Time Range	เอาเฉพาะช่วงเวลาไหน · อยู่ในกล่อง Filters	No filter

กับดักที่ทำให้ตารางว่างเปล่า

Time Range ต้องเป็น No filter ทุกกราฟ


ถ้าไม่ตั้ง

ค่าเริ่มต้นแสดงข้อมูลแค่ช่วงล่าสุด

ข้อมูลชุดนี้เป็นปี **2011** ทั้งหมด

คุณจะได้ ตารางว่าง หรือยอดที่น้อยกว่าความจริงมาก

และระบบไม่ฟ้องอะไรเลย กราฟยังวาดออกมาสวยเหมือนเดิม



กราฟแรก · ค่าที่ต้องกรอก

ตารางสรุปตามชั้นโดยสาร

ชนิดกราฟ : Table

Query mode : Aggregate

Time Range : No filter

Dimensions : Travel Class

Metrics : COUNT(*) และ SUM(Cost) <- - สองตัวในช่องเดียวกัน

- untitled

4 rows00:00:00.09

Travel Class	COUNT(*)	SUM(Cost)
Economy	2.46k	602k
Business	420	696k
Premium Economy	61	99.8k
First	9	1.71k

ผลลัพธ์ที่ควรได้ — 4 บรรทัด 3 คอลัมน์

Query

QUERY MODE

AGGREGATERAW RECORDS

GROUP BY

Travel Class

19 option(s)

METRICS

COUNT(*)

PERCENTAGE METRICS

+

+

SORT BY

+

+

My Metric

SIMPLESAVEDCUSTOM SQL

COLUMN

Cost

AGGREGATE

SUM

CLOSE

SAVE

ตั้ง SUM(Cost) ที่หน้าต่าง metric

วิธีรู้ว่าตัวเองทำถูก

บวกแล้วต้องได้ 2,954


บวกคอลัมน์จำนวนครั้งทั้งสี่บรรทัด แล้วเทียบกับจำนวนแถวทั้งหมดของ dataset

ถ้าได้	แปลว่า	แก้ที่
2,954	ถูกต้อง ไปต่อได้	—
น้อยกว่ามาก หรือตารางว่าง	Time Range ยังไม่ได้ตั้ง No filter	กล่อง Filters
เกิน 4 บรรทัด	ใส่ Dimensions เกินหนึ่งคอลัมน์	ช่อง Dimensions
เห็นข้อมูลดิบเป็นพันแถว	Query mode ยังเป็น Raw records	ช่อง Query mode


การมีตัวเลขให้เทียบ คือความต่างระหว่างการรู้ว่าถูก กับการเดาว่าน่าจะถูก

กราฟที่สอง

ตารางไขว้ ดูสองมิติพร้อมกัน



Rows: Department · Columns: Travel Class · SUM(Cost)



คำถามที่ตารางธรรมดาตอบไม่ได้ — แผนกไหนใช้ชั้นโดยสารอะไร

ช่องที่ว่างคือข้อมูล ไม่ใช่ความผิดพลาด — แปลว่าแผนกนั้นไม่เคยใช้ชั้นโดยสารนั้นเลย

ขั้นที่ 5 · คำอธิบาย

หัวคอลัมน์ที่ไม่บอกหน่วย คือหัวคอลัมน์ที่ยังไม่เสร็จ

SUM(Cost)

บอกแค่ว่า คำนวณยังไง
ไม่ได้บอกว่ามันคืออะไร และหน่วยอะไร

ค่าตัวรวม (ปอนด์)

คนอ่านรู้ทันทีที่กำลังดูอะไร
ช่อง Label ในหน้าต่าง metric คือที่ที่ใส่

ตัวเลข 1,657 ที่ไม่มีหน่วย คนไทยจะอ่านเป็นบาทโดยอัตโนมัติ ซึ่งต่างจากปอนด์อยู่สี่สิบกว่าเท่า

จุดที่พลาดกันมากที่สุด


แดชบอร์ดใบเดียวตลอดวิชา

ผิด

กด **Add to new dashboard** แล้วตั้งชื่อเดิม

Superset **ไม่ห้ามซ้ำ** คุณจะได้ใบที่สองที่ชื่อเหมือนกันเป๊ะ บันทึกสัปดาห์ที่ 1 อยู่ใบเก่า กราฟวันนี้อยู่ใบใหม่

ระบบตรวจย้อนดูงานเก่าทุกสัปดาห์ — ตกทั้งที่ทำครบ



แดชบอร์ดสร้างครั้งเดียวจบไปแล้ว **ตั้งแต่สัปดาห์ที่ 1** · สัปดาห์ 2 ถึง 10 ใช้ช่อง **Add to existing dashboard** ทุกครั้ง ไม่มีข้อยกเว้น

ส่งงาน: กด "ลองตรวจ" แล้ว "ส่งงาน" ที่ spu.minddatatech.com/assignment · ไม่ต้อง export ไฟล์ · ห้าม Publish