

สัปดาห์ที่ 6 • คู่มือบทที่ 8.4 ถึง 8.8

แดชบอร์ดที่คุณได้อย่างเดียว ตอบได้แค่คำถามที่คุณคิดไว้ล่วงหน้า

วันนี้ทำให้คนอ่านตั้งคำถามใหม่ของตัวเองได้ โดยไม่ต้องกลับมาหาคุณ

คู่มือบทที่ 8 หัวข้อ 8.4 ถึง 8.8 • นี่เป็นเนื้อหาที่เลิกก่อนหน้ายังไม่เคยแต่ละเลย

สี่เครื่องมือของวันนี้

เจาะลึก กรองข้าม แบ่งแท็บ ส่งออก

เครื่องมือ	ทำอะไร	เข้าถึงอย่างไร
Drill to detail	แสดงข้อมูลระดับแถวที่อยู่เบื้องหลังตัวเลขนั้น	คลิกขวาที่จุดข้อมูล
Drill by	หั่นตัวเลขเดิมด้วยคอลัมน์อื่นทันที ไม่ต้องแก้กราฟ	คลิกขวา แล้วเลือกคอลัมน์
Cross-filter	ใช้ค่าที่คลิกไปกรองกราฟอื่นทั้งหน้า	คลิกที่แท่งหรือชิ้นส่วนโดยตรง
View query	ดู SQL จริงที่ Superset ส่งไปฐานข้อมูล	เมนูจุดสามจุดของกราฟ

แท็บ

แยกภาพรวมออกจากรายละเอียด

แท็บ ภาพรวม


ตัวเลขใหญ่ · กราฟเส้น

สำหรับคนที่ต้องการคำตอบ ไม่ต้องการวิธีคิด

แท็บ เจาะลึก

ตาราง · ตารางไขว้ · กราฟแท่ง

สำหรับคนที่จะหาสาเหตุต่อ



ลากองค์ประกอบ **Tabs** มาวางบนสุด แล้วลากกราฟที่มีอยู่แล้วเข้าไป — **อย่าลบกราฟใด ๆ ทั้ง** · แท็บแต่ละแท็บมี URL ของตัวเอง ส่งให้คนอื่นเปิดตรงแท็บที่ต้องการได้

Cross-filter

ต่างจากตัวกรองที่คุณทำสัปดาห์ที่แล้ว

Native Filter (สัปดาห์ 5)

คำถามที่คุณเตรียมไว้ให้

คุณเลือกล่วงหน้าว่าจะให้กรองด้วยคอลัมน์อะไรได้บ้าง

Cross-filter (วันนี้)

คำถามที่คนอ่านคิดเองหน้างาน

คลิกที่อะไรก็กรองด้วยอันนั้น โดยที่คุณไม่ต้องเดาไว้ก่อน

เมนูจุดสามจุดของแดชบอร์ด > Enable cross-filtering

แล้วลองคลิกที่แท่งของชั้นโดยสารหนึ่งชั้น ดูว่ากราฟอื่นเปลี่ยนตามไหม

ทำไม Drill to detail ถึงสำคัญกว่าที่คิด

เครื่องมือที่ทำให้เถียงกันเรื่องตัวเลขจบได้

ไม่มี Drill to detail

"ตัวเลขนี้ผิดแน่ ๆ"

"ไม่ผิดครับ ผมเช็คแล้ว"

เถียงกันต่อด้วยความรู้สึกว่ใครน่าเชื่อถือกว่า

มี Drill to detail

คลิกขวา แล้วเปิดแถวจริงให้ดูตรงนั้น

จบใน 5 วินาที ด้วยหลักฐาน

ในหน้าต่าง Drill to detail และ Drill by มีปุ่ม **Download** ให้ส่งออกผลลัพธ์เป็น CSV หรือ Excel ได้ทั้งชุด ไม่ได้จำกัดเฉพาะหน้าที่เห็นอยู่

URL สำหรับฉายขึ้นจอ

พารามิเตอร์	ผล
?standalone=1	ซ่อนแถบเมนูด้านบน
?standalone=2	ซ่อนแถบเมนูและชื่อแดชบอร์ด
?standalone=3	ซ่อนแถบเมนู ชื่อ และแท็บระดับบนสุด
&show_filters=0	ไม่แสดงแถบตัวกรอง

เหมาะกับการฉายขึ้นจอในห้องประชุม
https://superset.minddatatech.com/superset/dashboard/csi414_66000001/?standalone=1&show_filters=0

ข้อควรระวังตอน Download CSV ถ้ากราฟตารางเปิดช่องค้นหาไว้และมีคำค้นค้างอยู่ ปุ่ม Download จะส่งออก เฉพาะแถวที่เห็นบนจอ ไม่ใช่ทั้งหมด — ล้างคำค้นก่อนเสมอ

สำรวจข้อมูลขั้นที่ 2 · ตัวแปรกระจายตัวอย่างไร

ค่าเฉลี่ยตัวเดียว เล่าเรื่องผิดได้ทั้งเรื่อง

video_game_sales (สาริต)

ยอดขายทั่วโลกต่อเกม - ค่าเฉลี่ย **0.54** ล้านชุด - มัธยฐาน **0.17** ล้านชุด -
สูงสุด **82.74** (Wii Sports)
เกมทั่วไปขายได้หนึ่งในสามของ "ค่าเฉลี่ย"

flights (ของคุณ)

delay ขาออก - ค่าเฉลี่ย **16.8** นาที - มัธยฐาน **2** นาที - 22,282 เที่ยวบิน
ออกก่อนเวลา
รายงานแค่ค่าเฉลี่ย = บอกว่าทุกเที่ยวช้า 17 นาที

mean ห่างจาก median มาก = หางยาว ที่สที่ mean ถูกลากไปคือทิศของหาง

จำนวน bin เปลี่ยนเรื่องที่กราฟเล่า

Bins	เห็นอะไร	ซ่อนอะไร
น้อยเกิน	ภาพรวมว่าเบ้ไปทางไหน	ยอดน้อย · ช่องว่าง · ค่าที่กองอยู่ที่ศูนย์
มากเกินไป	รายละเอียดทุกซอก	รูปทรงรวม — เห็นแต่พื้นเลื้อย

ช่วง `DEPARTURE_DELAY` คือ -39 ถึง **1,380** นาที · ถ้าไม่กรอง แท่งหนึ่งกว้าง 140 นาที เห็นแท่งเดียว
กรอง `<= 180` แล้วรูปจึงปรากฏ — แต่คุณเพิ่ง **ทิ้งไป 557 เทีย** ต้องเขียนกำกับทุกครั้ง

สำรวจข้อมูลขั้นที่ 2 · กัปดัก

SQL ที่รันผ่าน ไม่ได้แปลว่าถูก

```
CAST(DEPARTURE_DELAY / 10 AS INTEGER) * 10      -- แท่ง 0 = 32,579 เทียว  
CAST(FLOOR(DEPARTURE_DELAY / 10.0) * 10 AS INTEGER) -- แท่ง -10 = 21,432 · แท่ง 0 = 11,781
```

แบบแรกไม่มี error สักบรรทัด แต่ **CAST** ปิดเข้าหาศูนย์ ช่วง -9 ถึง 9 จึงถูกยุบเป็นแท่งเดียว
คนที่จับได้ คือคนที่เอาตัวเลขไป เทียบกับรูป

ตัดสินใจสัปดาห์นี้: รายงานด้วย median และเปอร์เซ็นต์ไทล์ · ระบุจำนวนที่ตัดออกจากกราฟ · ข้อมูลมีแค่ 4 วัน ข้อสรุปทุกข้อใช้ได้กับช่วงนี้เท่านั้น

สำรวจข้อมูลขั้นที่ 2 · SQL

ถามด้วย SQL ก่อน — ทายรูปทรงก่อนสร้างกราฟ

```
-- (■) ■■■■■■■■■■  
SELECT MIN(DEPARTURE_DELAY)      AS min_delay,  
       ROUND(AVG(DEPARTURE_DELAY), 1) AS mean_delay,  
       MAX(DEPARTURE_DELAY)      AS max_delay,  
       SUM(DEPARTURE_DELAY < 0)   AS left_early,  
       SUM(DEPARTURE_DELAY > 180) AS over_180  
FROM flights;
```

min	mean	max	ออกก่อนเวลา	ช้า > 180 นาที
-39	16.8	1,380	22,282 เที่ยวบิน	557 เที่ยวบิน

SUM(เงื่อนไข) ใน SQLite นับ TRUE=1 FALSE=0 — ใช้แทน COUNT(CASE WHEN...) ได้เลย

สำรวจข้อมูลขั้นที่ 2 · SQL

NTILE(100) — วิธีหา percentile ใน SQLite

```
-- (■) ■■■■■■■■■■■■■■ – SQLite ■■■■■ percentile_cont
SELECT pct, MAX(DEPARTURE_DELAY) AS delay_at_pct
FROM (SELECT DEPARTURE_DELAY,
             NTILE(100) OVER (ORDER BY DEPARTURE_DELAY) AS pct
      FROM flights WHERE DEPARTURE_DELAY IS NOT NULL)
WHERE pct IN (25, 50, 75, 90, 99)
GROUP BY pct;
```

p25	p50 (median)	p75	p90	p99
-3 นาที	2 นาที	21 นาที	54 นาที	183 นาที

median = 2 ห่างจาก mean = 16.8 มาก → mean ถูกลากโดยหางขวา — ทายรูปก่อนสร้าง histogram แล้วเทียบ

สำรวจข้อมูลขั้นที่ 2 · ข้อควรระวัง

กับดัก 3 อย่างที่เจอก่อนกราฟจะถูก

1. NULL → error

Histogram error: "non-numeric values"

เพราะมี NULL 1,195 แถว

แก้: Filter DEPARTURE_DELAY IS NOT NULL

2. 10,000 แถว → กราฟผิด ไม่มี error

Row limit เริ่มต้น 10k ทำให้แกนเปลี่ยน

-39...1,380 → -27...1,190

สังเกต: ป้าย "10k rows" สีแดง

→ ตั้ง Row limit $\geq 100,000$

3. Bar cross-filter ไม่ทำงาน

Bar ที่ใส่คอลัมน์แค่ใน X-axis

(Dimensions ว่าง) ไม่ส่ง cross-filter


แก้: ใช้ Table แบบ Aggregate แทน

กับดักข้อ 2 อันตรายที่สุด: ไม่มี error เลย — คนที่จับได้คือคนที่รู้ว่าช่วงควรเป็นเท่าไรจาก SQL ก่อน

สำรวจข้อมูลชั้นที่ 2 · กลุ่ม

กลุ่มไหนต่างจากกลุ่มอื่น — ใช้ cross-filter หา

สายการบิน (top 5 จาก 14 สาย)



วันในสัปดาห์ ← ข้อมูลมีแค่ 4 วัน



ข้อมูล flights มีแค่ 1–4 ม.ค. (4 วัน) — ทุกข้อสรุปต้องระบุว่า "ใช้ได้กับช่วงนี้เท่านั้น"

Bar DAY_OF_WEEK เห็น 4 แท่ง = หลักฐานว่าข้อมูลมีแค่ 4 วัน · ใช้ cross-filter คลิกสายการบินแล้วดู histogram เปลี่ยน

สำรวจข้อมูลขั้นที่ 2 . ตัดสินใจ

การกระจายของทั้งชุด ≠ ของทุกกลุ่ม

สาย	median	ข้อสังเกต
AS	-2 นาที	ออกก่อนเวลาโดยเฉลี่ย
WN	7 นาที	มีเที่ยวบินมากที่สุด 11,472 เที่ยวบิน
MQ	9 นาที	ช้ากว่า AS ถึง 11 นาที

ทำไม "ภาพรวม" ถึงเหมือน WN
WN มี 11,472 เที่ยวบิน = 21% ของทั้งชุด
histogram รวมจึงถูกดึงไปทาง WN

Decision log สัปดาห์ที่ 6

สิ่งที่พบ	หลักฐาน	ตัดสินใจ
delay เบ้ขวา mean=16.8 / median=2	histogram + SQL	รายงาน median + percentile
ข้อมูลมีแค่ 4 วัน (1-4 ม.ค.)	Bar DAY_OF_WEEK	ระบุข้อจำกัดช่วงเวลาทุกครั้ง
สายบินกระจายต่างกัน AS=-2 MQ=9	cross-filter + SQL	เทียบด้วย median ไม่ใช่ mean