

สัปดาห์ที่ 7 · คู่มือบทที่ 7


คำนวณเพิ่มจากผลลัพธ์ โดยไม่ต้องเขียน SQL

แท็บ Advanced Analytics ทำงานกับข้อมูลที่ฐานข้อมูลส่งกลับมาแล้ว ไม่ได้เปลี่ยนคำสั่งที่ส่งไป

สไลด์ที่ต้องรู้จัก: Rolling Window · Time Comparison · Resample · Annotation Layers

ทำงานตรงไหนของลำดับ

คำนวณหลังจากได้ผลลัพธ์แล้ว



กราฟตั้งต้น — ยังไม่มีการคำนวณเพิ่ม เส้นสีเขียวตามข้อมูลรายวันจริง

สิ่งที่ทำในแท็บนี้ **ไม่ได้ทำในฐานข้อมูล** แต่ทำกับผลลัพธ์ที่ส่งกลับมาแล้ว แปลว่าถ้าผลลัพธ์ถูกจำกัดด้วย Row limit ไว้ การคำนวณก็ทำกับเท่าที่ได้มาเท่านั้น

Rolling Window

เฉลี่ยเคลื่อนที่ ทำให้เห็นแนวโน้ม

Rolling Function : mean

Periods : 7

Min Periods : 7 <-- ช่องที่คนข้ามบ่อยที่สุด



เส้นเรียบขึ้น เห็นแนวโน้มชัด แต่ จุดสูงสุดจริงถูกกลบหายไป

กับดักของ Min Periods

เส้นช่วงต้นที่หลอกตาโดยไม่มีใครรู้

ไม่ตั้ง Min Periods

วันแรกเฉลี่ยจากข้อมูล 1 วัน วันที่สองจาก 2 วัน ไปจนครบ 7
เส้นช่วงต้นจึงเป็นค่าเฉลี่ยของข้อมูลไม่ครบ แต่ถูกวาดด้วยเส้นแบบเดีย
วกันเป๊ะ


ตั้ง Min Periods = 7

ช่วงที่ข้อมูลไม่ครบ หายไปจากกราฟ
คนอ่านจึงไม่มีทางเผลออ่านค่าที่ยังคำนวณไม่ครบ

ระบบตรวจของแล็บนี้เช็กว่าคุณตั้ง Min Periods ไว้หรือยัง ไม่ใช่แค่ตั้ง rolling


Time Comparison

เทียบกับช่วงก่อนหน้า



Actual values — วาดสองเส้นให้เทียบเอง


Calculation Type	ตัวเลขที่ได้	เหมาะกับคำถาม
Actual values	ค่าจริงทั้งสองช่วง	อยากเห็นระดับของทั้งคู่
Difference	ค่าใหม่ลบค่าเก่า	โตขึ้นเท่าไร เป็นหน่วยเดิม
Percentage change	สัดส่วนที่เปลี่ยน	โตขึ้นกี่เปอร์เซ็นต์




Difference — วาดเฉพาะส่วนต่าง เหนือศูนย์คือโตขึ้น

Resample และ Annotation

เติมช่องว่าง และบอกว่าเส้นประคืออะไร



Resample จัดข้อมูลให้เป็นช่วงเวลาสม่ำเสมอ · median ทนต่อค่าผิดปกติมากกว่า mean



Annotation Layer เส้นอ้างอิง เช่นเป้าหมาย หรือวันที่เกิดเหตุการณ์สำคัญ

เส้นประที่ไม่มีชื่อ คือเส้นที่คนอ่านต้องเดาว่ามันคืออะไร

ช่อง **Name** ของ annotation layer ไม่ใช่ของประดับ ระบบตรวจเช็คที่ตั้งชื่อหรือยัง
ตั้งชนิดเป็น Formula แล้วใส่ $y=1500$ เพื่อลากเส้นเป้าหมายในแนวนอน

ส่งงาน: กด "ลองตรวจ" แล้ว "ส่งงาน" ที่ spu.minddatatech.com/assignment · ไม่ต้อง export ไฟล์ · ห้าม Publish

สำรวจข้อมูลขั้นที่ 3 · ค่าไหนสุดโต่ง

อ่าน Box Plot ให้ออกในห้าวินาที

ส่วนประกอบ

- เส้นกลางกล่อง = **median**
- ขอบกล่อง = **Q1** และ **Q3**
- หนวด (Tukey) ยาวไม่เกิน **$1.5 \times \text{IQR}$**
- จุดนอกหนวด = สิ่งนี้นิยามนี้เรียกว่า outlier

นิยามเปลี่ยน outlier ก็เปลี่ยน

สาย	Q1	Q3	ขอบบน	เกินขอบ
AA	-3	30	79.5	423 เที้ยว
VX	-4	5	18.5	60 เที้ยว

ซ้ำ 60 นาทีเป็น outlier ของ VX แต่เป็นเรื่องปกติของ AA

outlier ไม่ใช่คุณสมบัติของข้อมูล มันคือคุณสมบัติของนิยามที่คุณเลือก

ดูคอลัมน์ข้างเคียงว่าสอดคล้องกันไหม

flights

ออกช้า 1,380 นาที และถึงช้าใกล้เคียงกัน
สองคอลัมน์ที่บันทึกแยกกันตรงกัน = เทียบบินค้างข้ามคืนจริง ไม่ใช่พิมพ์เลขเกิน

video_game_sales (สาริต)

Wii Sports 82.74 ล้าน โดดออกจากทุกกล่อง
ห้ามลบ — มันคือคำตอบของคำถาม "เกมอะไรขายดีที่สุด"

ทางเลือก	เมื่อไร
ลบ	พิสูจน์ได้ว่าเป็นข้อมูลผิด
ตัดเพดาน (cap)	ต้องการกราฟที่อ่านออก และบอกคนอ่านว่าตัด
เก็บไว้แต่ทำเครื่องหมาย	ของจริงที่บิดค่าเฉลี่ย — ทางที่เราเลือกกับ delay > 180 นาที (557 เที่ยวบิน)