

สัปดาห์ที่ 8 • คู่มือบทที่ 9 และ 5.6 ถึง 5.7

หกสัปดาห์ที่ผ่านมา คุณพิมพ์ AVG(Cost) ไปกี่ครั้งแล้ว

ครั้งแรกของคาบนี้คือการสรุปข้อมูลในฐานข้อมูล ครั้งหลังคือการเลิกเขียนสูตรซ้ำถาวร

ทำไมต้องสรุปในฐานข้อมูล

ข้อมูลที่ไม่ต้องเดินทาง คือข้อมูลที่มาถึงเร็ว

ดึงดิบมาแล้วค่อยรวม

2,954 แถวเดินทางผ่านเครือข่ายมาถึงเบราร์เซอร์
พอข้อมูลเป็นล้านแถว วิธีนี้ตายทันที

ให้ฐานข้อมูลรวมก่อน

ส่งกลับมาไม่กี่สิบแถว
ฐานข้อมูลถูกออกแบบมาเพื่อทำงานนี้โดยเฉพาะ

```
SELECT DATE_TRUNC('month', "Travel Date") AS "เดือน",  
       "Travel Class"                      AS "ชั้นโดยสาร",  
       AVG("Cost")                        AS "ค่าตัวเฉลี่ย",  
       COUNT(*)                          AS "จำนวนเที่ยว"  
FROM tutorial_flights  
GROUP BY 1, 2  
ORDER BY 1
```

จุดที่พลาดมากที่สุดในการเล่น

รัน SQL ทิ้งไว้เฉย ๆ ไม่ติดไปกับไฟล์

การกด Run แล้วเห็นผลลัพธ์ ไม่ได้แปลว่างานถูกบันทึก

ต้องกด **Save > Save dataset** ถึงจะกลายเป็น Dataset เสมือนที่ติดไปกับไฟล์ export

ถ้าไม่กด ระบบตรวจจะไม่เห็นงานส่วนนี้เลย และคุณจะตกทั้งที่ทำแล้ว

ทำอะไร	ติดไปกับ export ใหม่
พิมพ์ SQL แล้วกด Run	ไม่
กด Save > Save dataset	ใช่
สร้างกราฟจาก Dataset นั้น แล้วบันทึกลงแดชบอร์ด	ใช่

ครึ่งหลังของคาบ

ปัญหาที่ยังไม่มีใครเห็นว่าเป็นปัญหา

เขียน AVG(Cost) ในทุกกราฟ

กราฟ 5 รูป = สูตรเดียวกัน 5 ที่

วันที่นิยามเปลี่ยน เช่นต้องตัดตัวที่ยกเลิกออก ต้องไล่แก้ทีละรูป

วันที่ลืมนไปหนึ่งรูป แดชบอร์ดจะมีตัวเลขสองชุดที่ขัดกันเอง โดยไม่มีใคร
นะ

นิยาม metric ครั้งเดียวที่ Dataset

ทุกกราฟเรียกนิยามเดียวกัน

เปลี่ยนนิยาม = แก้ทีเดียวจบ

ตัวเลขขัดกันเองไม่ได้ตามโครงสร้าง

วิธีทำ

นิยาม metric กลางที่ Dataset

Datasets ▸ tutorial_flights ▸ ไอคอนดินสอ (Edit dataset) ▸ แท็บ Metrics

Metric Key : ค่าตัวเฉลี่ย Label : ค่าตัวเฉลี่ย (ปอนด์)

SQL Expression : AVG("Cost") D3 Format : ,.1f

Description : นับทุกเที่ยว ไม่ตัดตัวที่ยกเลิก

Be careful. Changing these settings will affect all charts using this dataset, including charts owned by other people.

SOURCE METRICS COLUMNS CALCULATED COLUMNS SETTINGS

+ ADD ITEM

Metric	Label	SQL Expression
ordercount	COUNT(OrderNumber)	COUNT(*)

LABEL
COUNT(OrderNumber)

DESCRIPTION
Description

D3 FORMAT
%y/%m/%d

WARNING MESSAGE
Warning Message

CERTIFIED BY
Srini


CERTIFICATION DETAILS
This metric is thoroughly validated!

USE LEGACY DATASOURCE EDITOR SAVE CANCEL


metric ที่นิยามตรงนี้ จะไปโผล่ในรายการ metric ของทุกกราฟที่ใช้ Dataset นี้

ทำไมถึงเรียกว่า Semantic Layer

ชั้นที่แปลจากคอลัมน์ เป็นคำที่คนในองค์กรพูด



ตั้งชื่อที่คนอ่านเข้าใจ (verbose name) แทนชื่อคอลัมน์ดิบในฐานข้อมูล



คอลัมน์คำนวณ — สร้างมิติใหม่จากคอลัมน์ที่มีอยู่ โดยไม่ต้องแตะฐานข้อมูล

เมื่อทุกกราฟเรียกนิยามเดียวกัน คำว่า "ค่าตัวเฉลี่ย" ในที่ประชุมจึงหมายถึงสิ่งเดียวกันจริง ๆ
นี่คือสิ่งที่แยกองค์กรที่เถียงกันเรื่องตัวเลขทุกสัปดาห์ ออกจากองค์กรที่เถียงกันเรื่องการตัดสินใจ

เลือกใช้ให้ถูกงาน

SQL Lab กับ Explore เหมาะกับคนละงาน

สถานการณ์	ใช้อะไร
ต้องรวมข้อมูลจากหลายตาราง	SQL Lab
ต้องคำนวณที่ Superset ไม่มีให้	SQL Lab
อยากลองเปลี่ยนมุมมองเร็ว ๆ ห้ารอบ	Explore
คนที่ใช้ต่อเขียน SQL ไม่เป็น	Explore บน Dataset ที่เตรียมไว้ให้

รูปแบบที่ใช้ได้ดีที่สุดในงานจริง — คนที่เขียน SQL เป็น เตรียม Dataset เสมือนและ metric กลางไว้ แล้วคนที่เหลือในทีมทำงานบน Explore ได้โดยไม่ต้องเขียน SQL เลย

สำรวจข้อมูลขั้นที่ 4 · จากการตัดสินใจ สู่โค้ดที่รันซ้ำได้

การวิเคราะห์ที่รันซ้ำไม่ได้ คือการวิเคราะห์ที่ไม่มีใครตรวจได้

สามสัปดาห์ที่ผ่านมา

คุณมี Saved Query `eda5` `eda6` `eda7` และ Decision log

วันนี้ รันซ้ำทั้งหมด — ต้องได้เลขเดิม

วันนี้

รวมการตัดสินใจเป็น Dataset เสมือน `flights_clean_<รหัส>`

`WHERE` จากสัปดาห์ 5 · เกณฑ์ 180 จากสัปดาห์ 6–7 · เกณฑ์ 15 นาที
จากกฎที่ค้นพบ

```
SELECT rowid AS id, *, SCHEDULED_DEPARTURE / 100 AS dep_hour,  
       CASE WHEN ARRIVAL_DELAY >= 15 THEN 1 ELSE 0 END AS is_delayed,  
       CASE WHEN DEPARTURE_DELAY > 180 THEN 1 ELSE 0 END AS is_outlier  
FROM flights WHERE CANCELLED = 0 AND DIVERTED = 0      -- 53,751 แถว
```

557 กลายเป็น 552 — ไม่มีใครนับผิด

สัปดาห์ 7 คุณนับ delay > 180 นาทีได้ **557** เทียบจากข้อมูลดิบ
ใน `flights_clean` เหลือ **552** เพราะอีก 5 เทียบถูกยกเลิกหรือเปลี่ยนเส้นทาง จึงหายไปตั้งแต่บรรทัด `WHERE`

ทุกตัวเลขในรายงานต้องบอกได้นับจากชุดไหน นี่คือเหตุผลที่นิยามต้องอยู่ที่เดียว

นิยามกลาง	อยู่ที่ไหน	ผล
<code>is_delayed</code> = ถึงช้า $\geq$ 15 นาที	คอลัมน์ใน <code>flights_clean</code>	ทั้งทีมใช้คำว่า "ล่าช้า" ตรงกัน
<code>on_time_rate</code> = <code>AVG(1 - is_delayed)</code>	metric ของ Dataset	VX 86% ... MQ 47% — ทุกกราฟได้เลขเดียวกัน