สัปดาห์ที่ 9 · คู่มือบทที่ 14

แผนที่นับสิ่งที่อยู่ในข้อมูล ไม่ได้นับสิ่งที่คุณคิดว่ามันนับ

แผนที่เป็นกราฟที่คนชอบมากที่สุดและใช้ผิดบ่อยที่สุด เพราะมันดูน่าเชื่อถือแม้ตอนที่ไม่ได้บอกอะไรเลย

Dataset วันนี้: `san_francisco` — ที่อยู่ในเมืองซานฟรานซิสโก 261,552 แถว ชุดตัวอย่างทางการของ Apache Superset

ก่อนจะเปิด deck.gl

เมื่อไรควรใช้แผนที่ เมื่อไรไม่ควร

ควรใช้	ไม่ควรใช้
คำถามเกี่ยวกับ **ตำแหน่ง** เช่นตรงไหนหนาแน่นกว่ากัน	คำถามเกี่ยวกับ **ปริมาณ** ที่ไม่เกี่ยวกับที่ตั้ง
อยากให้เห็นรูปทรงเชิงพื้นที่ที่ตารางบอกไม่ได้	มีแค่ไม่กี่พื้นที่ ซึ่งกราฟแท่งอ่านง่ายกว่ามาก
ข้อมูลมีพิกัดจริง ไม่ใช่แค่ชื่อจังหวัด	เอาแผนที่มาใส่เพราะมันดูดี

กฎง่าย ๆ ที่ใช้ได้เกือบทุกครั้ง
ถ้าคำตอบของคำถามยังเหมือนเดิมเมื่อสลับตำแหน่งพื้นที่บนแผนที่ แปลว่าคุณไม่ได้ต้องการแผนที่ คุณต้องการกราฟแท่ง

ความผิดพลาดอันดับหนึ่ง

สลับละติจูดกับลองจิจูด

สิ่งที่ต้องมี	ช่วงค่าที่ถูกต้อง
คอลัมน์ละติจูด `LAT`	-90 ถึง 90
คอลัมน์ลองจิจูด `LON`	-180 ถึง 180

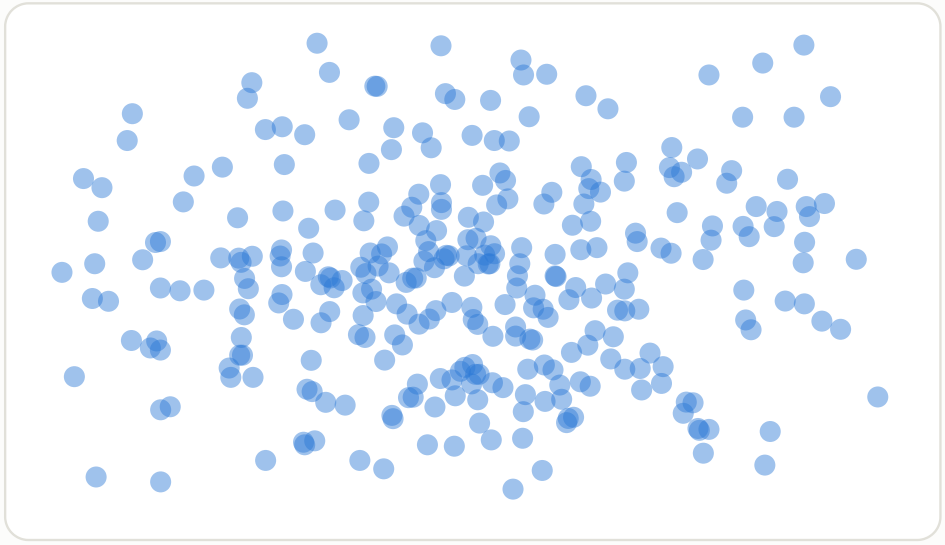
ใส่สลับกันแล้วแผนที่จะว่างเปล่า ไม่มีจุดสักจุด เพราะละติจูด −122 ไม่มีอยู่จริง
Superset วางช่อง **Longitude ไว้ซ้าย** Latitude ไว้ขวา ใครเลือกละติจูดก่อนตามความเคยชินจะสลับทันที และระบบจะไม่ฟ้อง
ถ้าเจออาการนี้ อย่าเพิ่งโทษข้อมูล ให้กลับไปดูสองช่องนี้ก่อนเสมอ — ระบบตรวจของแล็บนี้จับความผิดพลาดนี้ด้วย

```
ชนิดกราฟ : deck.gl Scatterplot
Longitude & Latitude : Longitude & Latitude columns
  Longitude : LON   (ช่องซ้าย)
  Latitude  : LAT   (ช่องขวา)      ปุ่มบนแผงต้องขึ้นว่า  LON | LAT
Row limit : 10000  ก่อน  แล้วค่อยเพิ่มเป็น 100000
```

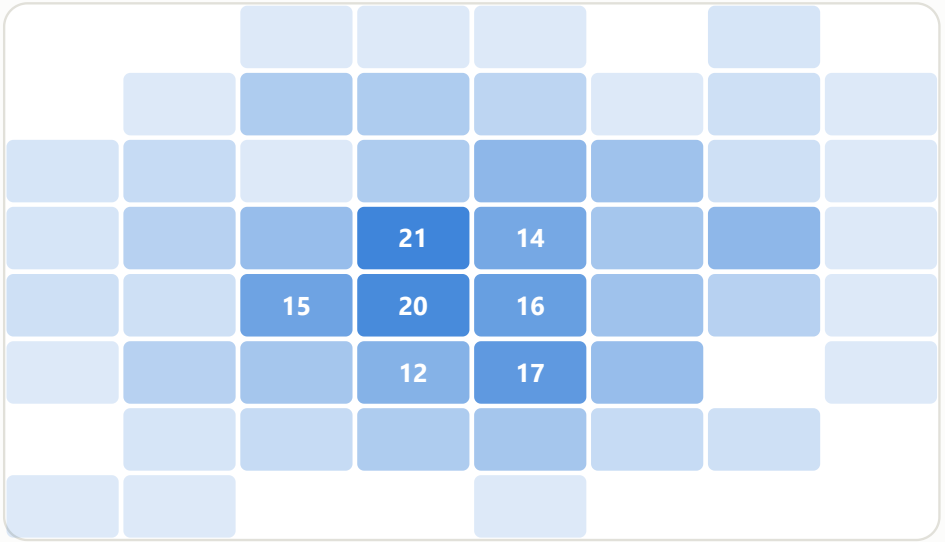
ปัญหาที่จะเจอด้วยตาตัวเอง

จุดทับกันจนนับไม่ได้

จุดดิบ ตรงกลางทับกันจนบอกไม่ได้ว่ามีกี่จุด



รวมจุดเป็นช่อง ความเข้มบอกจำนวนจุดในช่องนั้น



ทั้งสองภาพคือข้อมูลชุดเดียวกัน **การลดความทึบของจุดไม่ได้แก้ปัญหานี้** เพราะปัญหาอยู่ที่ยังไม่ได้รวมข้อมูล ไม่ได้อยู่ที่สี

ซ้ายคือจุดดิบ ขวาคือการรวมจุดเป็นช่อง ทั้งสองภาพคือข้อมูลชุดเดียวกัน

ทำไมวิธีที่คนลองก่อนถึงไม่ได้ผล

ปัญหาไม่ได้อยู่ที่การมองเห็น

วิธีที่มักลอง	ทำไมไม่ได้ผล
ลดความทึบของจุด	ช่วยได้นิดเดียว พอจุดทับกันสิบชั้นก็ทึบเหมือนเดิม
ลดขนาดจุด	อ่านตำแหน่งยากขึ้น แต่ตรงกลางยังนับไม่ได้อยู่ดี
เปลี่ยนสี	ไม่เกี่ยวกับปัญหาเลย

สายตาคนนับของซ้อนกันไม่ได้ ต้องให้การคำนวณนับให้ก่อน แล้วค่อยวาดผลลัพธ์
นี่คือเหตุผลที่ deck.gl Grid และ Hexagon มีอยู่ — แบ่งแผนที่เป็นช่อง แล้วนับค่าในแต่ละช่อง

ขนาดช่อง

ไม่มีขนาดที่ถูกเพียงขนาดเดียว

ช่องใหญ่เกินไป
รวมพื้นที่ที่ไม่เกี่ยวกันเข้าด้วยกัน จนดูเหมือนทั้งย่านหนาแน่นเท่ากัน

ช่องพอดี
เห็นความต่างระหว่างย่าน โดยยังบอกได้ว่าย่านไหนคือย่านไหน

ช่องเล็กเกินไป
กลับไปเหมือนจุดดิบ อ่านความหนาแน่นไม่ออก

ต้องเลือกให้เข้ากับคำถาม และ บอกคนอ่านว่าเลือกเท่าไร — ขนาดช่องเปลี่ยนข้อสรุปได้จริง

หัวใจของสัปดาห์นี้

ความหนาแน่นของจุด แทนอะไรกันแน่

> แผนที่จาก `san_francisco` แสดง **ความหนาแน่นของที่อยู่ที่ถูกบันทึกไว้**
> ซึ่ง **ไม่ใช่** ความหนาแน่นของประชากร — ตึกแถวหลังหนึ่งมีที่อยู่เดียวแต่มีคนอยู่ร้อยคน
> ซึ่ง **ไม่ใช่** ความหนาแน่นของกิจกรรมในเมือง และ **ไม่ใช่** ความหนาแน่นของปัญหา

คนอ่านจะสรุปเอาเองเสมอว่ามันนับสิ่งที่เขาสนใจ
หน้าที่ของคนทำคือเขียนกำกับให้ชัดว่ากำลังนับอะไรอยู่ — สามข้อที่ต้องมีในกล่อง Markdown

1. สีเข้มหรือช่องสูง แปลว่าอะไร
2. ขนาดช่องที่เลือกไว้เท่าไร
3. ข้อมูลมาจากไหนและเก็บเมื่อไร

สำรวจข้อมูลขั้นที่ 5 · อะไรสัมพันธ์กับอะไร

อ่าน scatter สามอย่าง: ทิศทาง ความแรง รูปทรง

คู่ตัวแปร (`flights_clean`)	r	แปลว่าอะไร
`DISTANCE` ~ `AIR_TIME`	**0.976**	บอกเรื่องเดียวกัน — ใส่ทั้งคู่ในโมเดลไม่ได้อะไรเพิ่ม (ซ้ำซ้อน)
`DEPARTURE_DELAY` ~ `ARRIVAL_DELAY`	**0.95**	แรงมาก แต่รู้ delay ขาออกได้ก็ต่อเมื่อเครื่องออกไปแล้ว = **leakage**
`DISTANCE` ~ `ARRIVAL_DELAY`	**−0.015**	บินไกลไม่ได้แปลว่าช้า

> **สาธิตด้วย `video_game_sales`:** `na_sales` ~ `eu_sales` สัมพันธ์บวก แต่ Wii Sports ดึงมุมกราฟ — กรองออกแล้วดูว่ารูปเปลี่ยนไหม นั่นคือ outlier บิดภาพความสัมพันธ์

แผนที่ก็คือ scatter ที่แกนเป็นลองจิจูดกับละติจูด ปัญหาจุดทับกันจึงแก้แบบเดียวกัน: รวมเป็นช่อง

สำรวจข้อมูลขั้นที่ 5 · r บอกไม่หมด

r = 0.18 แต่เป็นข้อค้นพบที่สำคัญที่สุดของชุดนี้

ถ้าเชื่อ r อย่างเดียว

ชั่วโมงออกเดินทาง ~ ล่าช้าหรือไม่

r ≈ 0.18 ดูเหมือนไม่มีอะไร

คุณจะทิ้งตัวแปรนี้

ถ้าดูกราฟด้วย

สัดส่วนเที่ยวบินที่ถึงช้า ≥ 15 นาที

06:00 → **20%** · 13:00 → **37%** · 21:00 → **46%**

ความล่าช้าสะสมทั้งวัน

r วัดแค่ **ความเป็นเส้นตรงของจุดรายแถว** ไม่ได้วัดว่ารูปแบบนั้นสำคัญแค่ไหน — ต้องมีทั้งตัวเลขและรูป

ตัดสินใจ: ใช้เฉพาะตัวแปรที่รู้ **ก่อน** ออกเดินทาง (`dep_hour` · `AIRLINE` · `ORIGIN_AIRPORT` · `DISTANCE` · `DAY_OF_WEEK`) · ตัด `AIR_TIME` (ซ้ำ) และ `DEPARTURE_DELAY` / `TAXI_OUT` / `WHEELS_OFF` (รู้ทีหลัง)