

สัปดาห์ที่ 9 • คู่มือบทที่ 14

แผนที่นับสิ่งที่อยู่ในข้อมูล ไม่ได้นับสิ่งที่คุณคิดว่ามันนับ

แผนที่เป็นกราฟที่คนชอบมากที่สุดและใช้ผิดบ่อยที่สุด เพราะมันดูน่าเชื่อถือแม้ตอนที่มันได้บอกอะไรเลย

Dataset วันนี้: `san_francisco` — ที่อยู่ในเมืองซานฟรานซิสโก 261,552 แถว ชุดตัวอย่างทางการของ Apache Superset

ก่อนจะเปิด [deck.gl](#)

เมื่อไรควรใช้แผนที่ เมื่อไรไม่ควร

ควรใช้	ไม่ควรใช้
คำถามเกี่ยวกับ ตำแหน่ง เช่นตรงไหนหนาแน่นกว่ากัน	คำถามเกี่ยวกับ ปริมาณ ที่ไม่เกี่ยวกับที่ตั้ง
อยากให้เห็นรูปทรงเชิงพื้นที่ที่ตารางบอกไม่ได้	มีแค่ไม่กี่พื้นที่ ซึ่งกราฟแท่งอ่านง่ายกว่ามาก
ข้อมูลมีพิกัดจริง ไม่ใช่แค่ชื่อจังหวัด	เอาแผนที่มาใส่เพราะมันดูดี
กล้วย ๆ ที่ใช้ได้เกือบทุกครั้ง ถ้าคำตอบของคำถามยังเหมือนเดิมเมื่อสลับตำแหน่งพื้นที่บนแผนที่ แปลว่าคุณไม่ได้ต้องการแผนที่ คุณต้องการกราฟแท่ง	

ความผิดพลาดอันดับหนึ่ง

สลับละติจูดกับลองจิจูด

สิ่งที่ต้องมี	ช่วงค่าที่ถูกต้อง
คอลัมน์ละติจูด LAT	-90 ถึง 90
คอลัมน์ลองจิจูด LON	-180 ถึง 180

ใส่สลับกันแล้วจุดทั้งหมดจะไปโผล่กลางมหาสมุทรอินเดีย เพราะละติจูด 122 ไม่มีอยู่จริง
ระบบจะไม่ฟ้อง มันจะวาดให้ตามที่ตั้ง
ถ้าเจออาการนี้ อย่าเพิ่งโทษข้อมูล ให้กลับไปดูสองช่องนี้ก่อนเสมอ — ระบบตรวจของแล็บนี้จับความผิดพลาดนี้ด้วย


```
ชนิดกราฟ : deck.gl Scatterplot
Longitude & Latitude : latitude/longitude columns
Latitude : LAT
Longitude : LON
Row limit : 10000 ก่อน แล้วค่อยเพิ่มเป็น 100000
```

ปัญหาที่จะเจอด้วยตัวเอง

จุดทับกันจนนับไม่ได้


จุดดิบ

ตรงกลางทับกันจนบอกไม่ได้ว่ามีจุด



รวมจุดเป็นช่อง

ความเข้มบอกจำนวนจุดในช่องนั้น



ทั้งสองภาพคือข้อมูลชุดเดียวกัน การลดความทึบของจุดไม่ได้แก้ปัญหานี้ เพราะปัญหาอยู่ที่ยังไม่ได้รวมข้อมูล ไม่ได้อยู่ที่สี

ซ้ายคือจุดดิบ ขวาคือการรวมจุดเป็นช่อง ทั้งสองภาพคือข้อมูลชุดเดียวกัน

ทำไมวิธีที่คนลองก่อนถึงไม่ได้ผล

ปัญหาไม่ได้อยู่ที่การมองเห็น

วิธีที่มักลอง	ทำไมไม่ได้ผล
ลดความทึบของจุด	ช่วยได้นิดเดียว พอจุดทับกันสีบชั้นก็ทึบเหมือนเดิม
ลดขนาดจุด	อ่านตำแหน่งยากขึ้น แต่ตรงกลางยังนับไม่ได้อยู่ดี
เปลี่ยนสี	ไม่เกี่ยวกับปัญหาเลย

สายตาคนนับของซ้อนกันไม่ได้ ต้องให้การคำนวณนับให้ก่อน แล้วค่อยวาดผลลัพธ์
นี่คือเหตุผลที่ deck.gl Grid และ Hexagon มีอยู่ — แบ่งแผนที่เป็นช่อง แล้วนับค่าในแต่ละช่อง

ขนาดช่อง

ไม่มีขนาดที่ถูกเพียงขนาดเดียว

ช่องใหญ่เกินไป

รวมพื้นที่ที่ไม่เกี่ยวข้องกันเข้าด้วยกัน จนดูเหมือน
ทั้งย่านหนาแน่นเท่ากัน

ช่องพอดี

เห็นความต่างระหว่างย่าน โดยยังบอกได้ว่า
ย่านไหนคือย่านไหน

ช่องเล็กเกินไป

กลับไปเหมือนจุดดิบ อ่านความหนาแน่นไม่
ออก

ต้องเลือกให้เข้ากับคำถาม และ บอกคนอ่านว่าเลือกเท่าไร — ขนาดช่องเปลี่ยนข้อสรุปได้จริง

ความหนาแน่นของจุด แทนอะไรกันแน่

แผนที่จาก `san_francisco` แสดง ความหนาแน่นของที่อยู่ที่ถูกบันทึกไว้
ซึ่ง **ไม่ใช่** ความหนาแน่นของประชากร — ดึกแถวหลังหนึ่งมีที่อยู่เดียวแต่มีคนอยู่ร้อยคน
ซึ่ง **ไม่ใช่** ความหนาแน่นของกิจกรรมในเมือง และ **ไม่ใช่** ความหนาแน่นของปัญหา

คนอ่านจะสรุปเอาเองเสมอว่ามันนับสิ่งที่เขาสนใจ

หน้าที่ของคนทำคือเขียนกำกับให้ชัดว่ากำลังนับอะไรอยู่ — สามข้อที่ต้องมีในกล่อง Markdown

1. สีเข้มหรือช่องสูง แปลว่าอะไร
2. ขนาดช่องที่เลือกไว้เท่าไร
3. ข้อมูลมาจากไหนและเก็บเมื่อไร

สำรวจข้อมูลขั้นที่ 5 · อะไรสัมพันธ์กับอะไร

อ่าน scatter สามอย่าง: ทิศทาง ความแรง รูปทรง

คู่ตัวแปร (flights_clean)	r	แปลว่าอะไร
DISTANCE ~ AIR_TIME	0.976	บอกเรื่องเดียวกัน — ใส่ทั้งคู่ในโมเดลไม่ได้อะไรเพิ่ม (ซ้ำซ้อน)
DEPARTURE_DELAY ~ ARRIVAL_DELAY	0.95	แรงมาก แต่รู้ delay ขาออกได้ก็ต่อเมื่อเครื่องออกไปแล้ว = leakage
DISTANCE ~ ARRIVAL_DELAY	-0.015	บินไกลไม่ได้แปลว่าช้า

สาริตด้วย video_game_sales : na_sales ~ eu_sales สัมพันธ์บวก แต่ Wii Sports ดึงมุมกราฟ — กรองออกแล้วดูว่ารูปเปลี่ยนไหม นั่นคือ outlier บิดภาพความสัมพันธ์

แผนที่ก็คือ scatter ที่แกนเป็นลองจิจูดกับละติจูด ปัญหาจุดทับกันจึงแก้แบบเดียวกัน: รวมเป็นช่อง

สำรวจข้อมูลชั้นที่ 5 · r บอกไม่หมด

$r = 0.18$ แต่เป็นข้อค้นพบที่สำคัญที่สุดของชุดนี้

ถ้าเชื่อ r อย่างเดียว

ชั่วโมงออกเดินทาง ~ ล่าช้าหรือไม่

$r \approx 0.18$ ดูเหมือนไม่มีอะไร

คุณจะทำตัวแปรนี้

ถ้าดูกราฟด้วย

สัดส่วนเที่ยวบินที่ถึงช้า ≥ 15 นาที

06:00 → **20%** · 13:00 → **37%** · 21:00 → **46%**

ความล่าช้าสะสมทั้งวัน

r วัดแค่ ความเป็นเส้นตรงของจุดรายแถว ไม่ได้วัดว่ารูปแบบนั้นสำคัญแค่ไหน — ต้องมีทั้งตัวเลขและรูป

ตัดสินใจ: ใช้เฉพาะตัวแปรที่รู้ **ก่อน** ออกเดินทาง (`dep_hour` · `AIRLINE` · `ORIGIN_AIRPORT` · `DISTANCE` · `DAY_OF_WEEK`) · ตัด `AIR_TIME` (ช้า) และ `DEPARTURE_DELAY` / `TAXI_OUT` / `WHEELS_OFF` (รู้ทีหลัง)