

สัปดาห์ที่ 10 • คู่มือบทที่ 10

งานที่ทำเสร็จ กับงานที่ส่งมอบได้ ไม่ใช่อันเดียวกัน

สัปดาห์สุดท้ายของภาคเรียนรู้เครื่องมือ ก่อนเริ่มโปรเจกต์ของตัวเองสัปดาห์หน้า

สิ่งที่ทำวันนี้คือสิ่งที่ทำให้คนอื่นรับงานคุณไปทำต่อได้ โดยไม่ต้องโทรถาม

แคช

การโกหกที่ตกลงกันไว้ล่วงหน้า


เวลาตั้งแคชหนึ่งชั่วโมง คุณกำลังบอกว่า "ตัวเลขที่เก่าได้ถึงหนึ่งชั่วโมง ยังใช้ตัดสินใจได้"
ถ้าข้อมูลจริงเปลี่ยนทุกนาที คนอ่านจะเห็นตัวเลขเก่า โดยไม่มีอะไรบนหน้าจอบอกเขาเลย

ข้อมูลแบบนี้	ควรตั้งแคช	ถ้าตั้งนานเกินไป
ข้อมูลย้อนหลังที่ไม่เปลี่ยนแล้ว	นานได้ เช่น 1 ชั่วโมงขึ้นไป	ไม่มีผลเสีย
ยอดขายที่อัปเดตทุกคืน	ไม่เกินรอบการอัปเดต	เห็นยอดเมื่อวานทั้งที่ของวันนี้มาแล้ว
จำนวนคนในห้องที่อัปเดตทุกนาที	สั้นมาก หรือไม่แคชเลย	ตัดสินใจจากตัวเลขที่ไม่จริงแล้ว


Datasets ▸ Edit dataset ▸ Settings ▸ Cache timeout : 3600
Dashboard Properties ▸ Styling ▸ Show last queried time : เปิดเสมอเมื่อใช้แคช

สิทธิ์

สองเงื่อนไขที่ต้องครบ คนอื่นถึงจะเห็นงานคุณ



เงื่อนไขที่ 1 แดชบอร์ดต้อง Published — ที่เป็น Draft คนอื่นมองไม่เห็นแม้จะรู้ URL



เงื่อนไขที่ 2 เราต้องมีสิทธิ์เข้าถึง **Dataset** ที่แดชบอร์ดใช้

นี่คือเหตุผลที่ใบงานทุกสัปดาห์สั่งว่าห้าม Publish

แดชบอร์ดที่เป็น Draft เพื่อนร่วมชั้นมองไม่เห็น งานของคุณจึงไม่ถูกลอกโดยอัตโนมัติ โดยที่ไม่ต้องตั้งค่าอะไรเพิ่มเลย

ข้างในไฟล์ export

สัฟโพลเดอร์ที่ต้องมีครบ

csi414_66000001.zip

— metadata.yaml	เวอร์ชันและชนิดของไฟล์
— dashboards/	ผังหน้าจอ แท็บ ตัวกรอง
— charts/	การตั้งค่าของกราฟทุกรูป
— datasets/examples/	นิยาม metric และคอลัมน์
— databases/examples.yaml	วิธีต่อฐานข้อมูล

รหัสผ่านฐานข้อมูลถูกแทนที่ด้วย `xxxxxxxxxx` เสมอตอน export

คนที่ import ต้องกรอกรหัสผ่านเองตอนนำเข้า ถ้าส่งไฟล์ให้ใครแล้วเขาบอกว่าเปิดไม่ได้ ให้ถามชื่อนี้ก่อนเสมอ

ไฟล์ export คือสิ่งเดียวที่คนรับงานได้ไป — สัฟโพลเดอร์นี้ขาดอันใดอันหนึ่ง เขาเปิดงานคุณไม่ได้

เอกสารส่งมอบ

หกบรรทัดที่ทำให้ไม่มีใครต้องโทรถาม

<ชื่อแดชบอร์ด>

****คำถามที่ตอบ**** ...

****ข้อมูล**** มาจากไหน ครอบคลุมช่วงไหน ก็แถว

****หน่วย**** ...

****นิยาม metric**** ค่าตัวเฉลี่ย คือ AVG(Cost) นับทุกเที่ยว ไม่ตัดตัวที่ยกเลิก

****ความสดของข้อมูล**** ตั้งแคชไว้เท่าไร เพราะอะไร

****คนดูแล**** ชื่อและวิธีติดต่อ

บรรทัด **นิยาม metric** คือบรรทัดที่คนมักสับสน และเป็นบรรทัดที่ทำให้เกิดการเถียงกันเรื่องตัวเลขมากที่สุด เพราะสองคนที่ใช้คำเดียวกันโดยนิยามไม่ตรงกัน จะไม่มีวันรู้ตัวว่าคุยกันคนละเรื่อง

รายการตรวจก่อนส่งมอบ

- ทุกกราฟมีชื่อที่เป็นภาษาคน ไม่มีชื่อค่าเริ่มต้นหลงเหลือ
- ทุกกราฟที่มีแกน มีชื่อแกนและหน่วย
- กล่อง Markdown ครบทั้งหกข้อ
- ตั้งแคชแล้วและอธิบายเหตุผลไว้
- เปิด Show last queried time แล้ว
- **กลับเป็น Draft แล้ว** ก่อน export ส่งงาน

สัปดาห์หน้าเริ่มโปรเจกต์

แดชบอร์ดที่คุณสร้างมาเก่าสัปดาห์ คือหลักฐานว่าคุณใช้เครื่องมือเป็นแล้ว

ตั้งแต่สัปดาห์ที่ 11 คุณจะเลือกคำถามของตัวเอง หาข้อมูลเอง และตอบมันด้วยเครื่องมือชุดเดียวกันนี้

สำรวจข้อมูลขั้นสุดท้าย · สรุปลงให้คนสร้างโมเดลใช้ต่อ

จากกราฟที่ทำให้ตัวเองเข้าใจ สู่หน้าเดียวที่ทำให้คนอื่นใช้ถูก

Exploratory (สัปดาห์ 5–9)

ทำให้ ตัวเอง เข้าใจ · จะรักก็ได้ ขอให้เร็ว · กราฟสืบทอดรูป

Explanatory (วันนี้)

ทำให้ คนที่ไม่ได้นั่งทำด้วย เข้าใจ · เหลือไม่เกิน 5 รูป · รูปไหนไม่ทำให้ ตัดสินใจอะไรได้ เอาออก

Data Understanding Brief หนึ่งหน้า ต้องมี

หัวข้อ	ตัวอย่างจาก <code>flights</code>
เป้าหมายที่แนะนำ	<code>is_delayed</code> — 33.1% ไม่สมดุลระดับปานกลาง
ตัวแปรที่น่าใช้ / ห้ามใช้	<code>dep_hour</code> ใช้ได้ · <code>DEPARTURE_DELAY</code> ห้าม (รู้ทีหลัง)
ค่าหาย · outlier	3 แบบ และวิธีจัดการ · 552 แถว flag ไว้ ไม่ลบ
ข้อจำกัด	ข้อมูล 4 วันแรกของปี ช่วงวันหยุด ไม่แทนทั้งปี
ตรวจซ้ำได้อย่างไร	SQL ของ <code>flights_clean</code> + query ที่ใช้ยืนยันทุกตัวเลข

สำรวจข้อมูลขั้นสุดท้าย . สิ่งที่แยก brief ออกจากสไลด์สวย ๆ

คนรับงานต้องรัน SQL ของคุณ แล้วได้เลขเดียวกัน

ถ้าคุณลืมเขียนว่าข้อมูลมีแค่ 4 วัน เขาจะสร้างโมเดลทำนายทั้งปีจากวันหยุดปีใหม่
เขาไม่ได้นั่งทำ EDA มาด้วย และจะ เชื่อทุกอย่างที่คุณเขียน

1. ก่อนเขียน รัน Saved Query `eda5` ถึง `eda9` อีกรอบ ตัวเลขทุกตัวต้องมาจากผลรันวันนี้ ไม่ใช่จากความจำ
2. Saved Query เห็นได้เฉพาะเจ้าของ — คัดลอกตัว SQL ลงใน brief ไม่ใช่บอกแค่ชื่อ
3. ไฟล์ export ของสัปดาห์นี้พา brief ไปด้วย = ชิ้นงานที่ส่งต่อให้ทีม ML ได้ทันที