สัปดาห์ที่ 10 · คู่มือบทที่ 10

งานที่ทำเสร็จ กับงานที่ส่งมอบได้ ไม่ใช่อันเดียวกัน

สัปดาห์สุดท้ายของภาคเรียนรู้เครื่องมือ ก่อนเริ่มโปรเจกต์ของตัวเองสัปดาห์หน้า

สิ่งที่ทำวันนี้คือสิ่งที่ทำให้คนอื่นรับงานคุณไปทำต่อได้ โดยไม่ต้องโทรถาม

แคช

การโกหกที่ตกลงกันไว้ล่วงหน้า

> เวลาตั้งแคชหนึ่งชั่วโมง คุณกำลังบอกว่า **"ตัวเลขที่เก่าได้ถึงหนึ่งชั่วโมง ยังใช้ตัดสินใจได้"**
> ถ้าข้อมูลจริงเปลี่ยนทุกนาที คนอ่านจะเห็นตัวเลขเก่า **โดยไม่มีอะไรบนหน้าจอบอกเขาเลย**

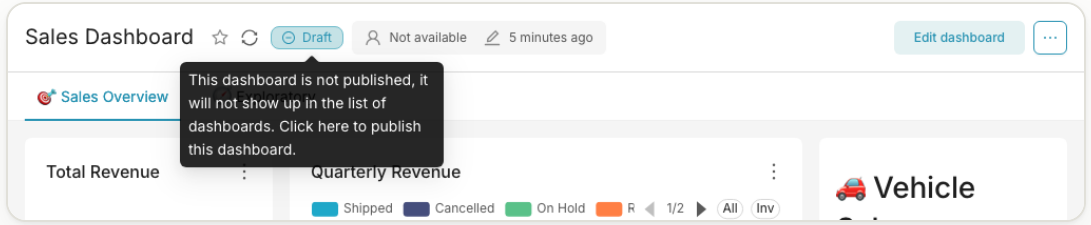
ข้อมูลแบบนี้	ควรตั้งแคช	ถ้าตั้งนานเกินไป
ข้อมูลย้อนหลังที่ไม่เปลี่ยนแล้ว	นานได้ เช่น 1 ชั่วโมงขึ้นไป	ไม่มีผลเสีย
ยอดขายที่อัปเดตทุกคืน	ไม่เกินรอบการอัปเดต	เห็นยอดเมื่อวานทั้งที่ของวันนี้มาแล้ว
จำนวนคนในห้องที่อัปเดตทุกนาที	สั้นมาก หรือไม่แคชเลย	ตัดสินใจจากตัวเลขที่ไม่จริงแล้ว

```
Datasets ▸ <Dataset ของคุณ> ▸ Edit dataset ▸ Settings ▸ Cache timeout : 3600
แดชบอร์ด ▸ ⋮ ของกราฟ ▸ Fetched / Cached … ago ▸ Force refresh
```

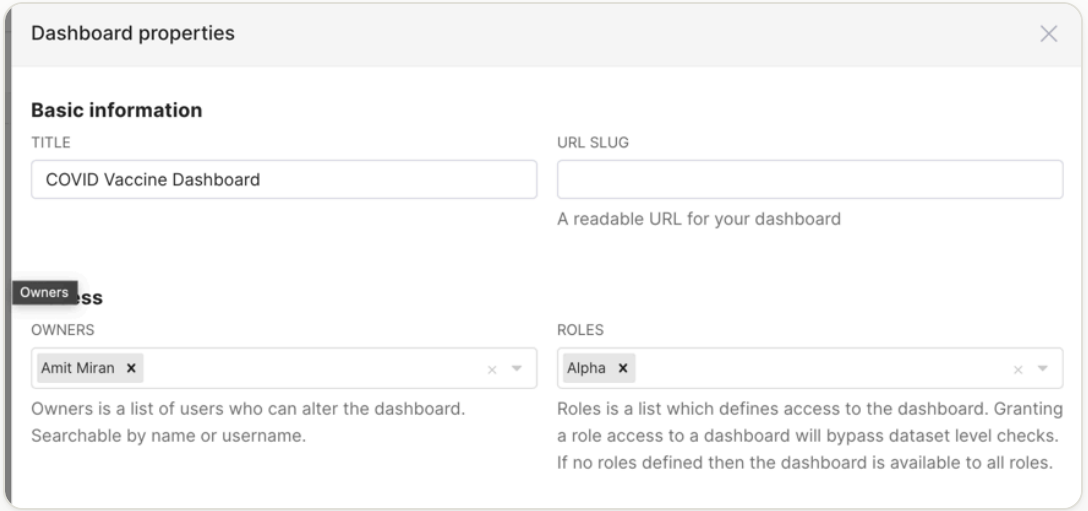
Superset 4.1 ไม่มีป้ายเวลาบนกราฟตลอดเวลา — จึงต้องเขียนความสดของข้อมูลไว้ในเอกสารส่งมอบ

สิทธิ์

สองเงื่อนไขที่ต้องครบ คนอื่นถึงจะเห็นงานคุณ



เงื่อนไขที่ 1 แดชบอร์ดต้อง Published — ที่เป็น Draft คนอื่นมองไม่เห็นแม้จะรู้ URL



เงื่อนไขที่ 2 เขาต้องมีสิทธิ์เข้าถึง **Dataset** ที่แดชบอร์ดใช้

นี่คือเหตุผลที่ใบงานทุกสัปดาห์สั่งว่าห้าม Publish

แดชบอร์ดที่เป็น Draft เพื่อนร่วมชั้นมองไม่เห็น งานของคุณจึงไม่ถูกลอกโดยอัตโนมัติ โดยที่ไม่ต้องตั้งค่าอะไรเพิ่มเลย

เซิร์ฟเวอร์ของวิชาเพิ่มอีกชั้น: นักศึกษาเปิดใน Explore ได้เฉพาะกราฟที่ตัวเองเป็นเจ้าของ — แม้แดชบอร์ดจะ Publish แล้ว

ข้างในไฟล์ export

สี่โฟลเดอร์ที่ต้องมีครบ

```
csi414_66000001.zip
├── metadata.yaml              เวอร์ชันและชนิดของไฟล์
├── dashboards/                ผังหน้าจอ แท็บ ตัวกรอง
├── charts/                    การตั้งค่าของกราฟทุกรูป
├── datasets/                  นิยาม metric และคอลัมน์ (แยกตามฐาน)
├── databases/lab_db.yaml      PostgreSQL — มีรหัสผ่าน
└── databases/examples.yaml    SQLite — ไฟล์ ไม่มีรหัสผ่าน
```

รหัสผ่านฐานข้อมูลถูกแทนที่ด้วย `XXXXXXXXXX` เสมอตอน export

คนที่ import ต้องกรอกรหัสผ่านเองตอนนำเข้า ถ้าส่งไฟล์ให้ใครแล้วเขาบอกว่าเปิดไม่ได้ ให้ถามข้อนี้ก่อนเสมอ

ไฟล์ export คือสิ่งเดียวที่คนรับงานได้ไป — สี่โฟลเดอร์นี้ขาดอันใดอันหนึ่ง เขาเปิดงานคุณไม่ได้

เอกสารส่งมอบ

หกบรรทัดที่ทำให้ไม่มีใครต้องโทรถาม

```
## <ชื่อแดชบอร์ด>

**คำถามที่ตอบ** ...
**ข้อมูล** มาจากไหน ครอบคลุมช่วงไหน กี่แถว
**หน่วย** ...
**นิยาม metric** ค่าตั๋วเฉลี่ย คือ AVG(Cost) นับทุกเที่ยว ไม่ตัดตั๋วที่ยกเลิก
**ความสดของข้อมูล** ตั้งแคชไว้เท่าไร เพราะอะไร · ⋮ ▸ Force refresh
**คนดูแล** ชื่อและวิธีติดต่อ
```

บรรทัด **นิยาม metric** คือบรรทัดที่คนมักลืม และเป็นบรรทัดที่ทำให้เกิดการเถียงกันเรื่องตัวเลขมากที่สุด เพราะสองคนที่ใช้คำเดียวกันโดยนิยามไม่ตรงกัน จะไม่มีวันรู้ตัวว่าคุยกันคนละเรื่อง

ก่อนจบภาคเรียนรู้เครื่องมือ

รายการตรวจก่อนส่งมอบ

- ทุกกราฟมีชื่อที่เป็นภาษาคน ไม่มีชื่อค่าเริ่มต้นหลงเหลือ
- ทุกกราฟที่มีแกน มีชื่อแกนและหน่วย
- กล่อง Markdown ครบทั้งหกข้อ
- ตั้งแคชบน Dataset ของตัวเอง (หรือบนกราฟ) แล้ว และอธิบายเหตุผลไว้
- เขียนความสดของข้อมูลและวิธี Force refresh ไว้ในกล่อง Markdown
- **กลับเป็น Draft แล้ว** ก่อนกดส่งงาน

> **สัปดาห์หน้าเริ่มโปรเจกต์**
> แดชบอร์ดที่คุณสร้างมาเก้าสัปดาห์ คือหลักฐานว่าคุณใช้เครื่องมือเป็นแล้ว
> ตั้งแต่สัปดาห์ที่ 11 คุณจะเลือกคำถามของตัวเอง หาข้อมูลเอง และตอบมันด้วยเครื่องมือชุดเดียวกันนี้

ส่งงาน: กด "ลองตรวจ" แล้ว "ส่งงาน" ที่ `spu.minddatatech.com/assignment` · ไม่ต้อง export ไฟล์ · ตั้งกลับเป็น Draft ก่อน

สำรวจข้อมูลขั้นสุดท้าย · สรุปให้คนสร้างโมเดลใช้ต่อ

จากกราฟที่ทำให้ตัวเองเข้าใจ สู่หน้าเดียวที่ทำให้คนอื่นใช้ถูก

Exploratory (สัปดาห์ 5–9)
ทำให้ **ตัวเอง** เข้าใจ · จะรกก็ได้ ขอให้เร็ว · กราฟสิบกว่ารูป

Explanatory (วันนี้)
ทำให้ **คนที่ไม่ได้นั่งทำด้วย** เข้าใจ · เหลือไม่เกิน 5 รูป · รูปไหนไม่ทำให้ตัดสินใจอะไรได้ เอาออก

Data Understanding Brief หนึ่งหน้า ต้องมี

หัวข้อ	ตัวอย่างจาก `flights`
เป้าหมายที่แนะนำ	`is_delayed` — 33.1% ไม่สมดุลระดับปานกลาง
ตัวแปรที่น่าใช้ / ห้ามใช้	`dep_hour` ใช้ได้ · `DEPARTURE_DELAY` ห้าม (รู้ทีหลัง)
ค่าหาย · outlier	3 แบบ และวิธีจัดการ · 552 แถว flag ไว้ ไม่ลบ
ข้อจำกัด	ข้อมูล 4 วันแรกของปี ช่วงวันหยุด ไม่แทนทั้งปี
ตรวจซ้ำได้อย่างไร	SQL ของ `flights_clean` + query ที่ใช้ยืนยันทุกตัวเลข

สำรวจข้อมูลขั้นสุดท้าย · สิ่งที่แยก brief ออกจากสไลด์สวย ๆ

คนรับงานต้องรัน SQL ของคุณ แล้วได้เลขเดียวกัน

> ถ้าคุณลืมเขียนว่าข้อมูลมีแค่ 4 วัน เขาจะสร้างโมเดลทำนายทั้งปีจากวันหยุดปีใหม่
> เขาไม่ได้นั่งทำ EDA มาด้วย และจะ **เชื่อทุกอย่างที่คุณเขียน**

1. ก่อนเขียน **รัน Saved Query** `eda5` **ถึง** `eda9` **อีกรอบ** ตัวเลขทุกตัวต้องมาจากผลรันวันนี้ ไม่ใช่จากความจำ
2. Saved Query เห็นได้เฉพาะเจ้าของ — **คัดลอกตัว SQL ลงใน brief** ไม่ใช่บอกแค่ชื่อ
3. ไฟล์ export ของสัปดาห์นี้พา brief ไปด้วย = ชิ้นงานที่ส่งต่อให้ทีม ML ได้ทันที